

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN 1



BÁO CÁO BÀI TẬP
Chủ đề: Bài Assignment02

Student name:

Dương Minh Thái

Student ID:

B23DCCN742

Class:

05

Team:

46-50

Lecturer:

Dinh Que Tran, Ph.D., Assoc. Prof.

Seemster:

I.2026

Hà Nội - 08/2026

1. TÓM TẮT (EXECUTIVE SUMMARY).....	4
2. KẾT NỐI VỚI LECTURE 02: BIỂU DIỄN DỮ LIỆU	5
Trả lời các câu hỏi chung (áp dụng cho cả 3 ứng dụng).....	5
2.1 Bảng ký hiệu tham số chuẩn (Notation)	5
2.2 Công thức và ý nghĩa các chỉ số đánh giá (Evaluation Metrics)	6
a) Chỉ số cho bài toán phân lớp (Diabetes, Customer Behavior).....	6
b) Chỉ số cho bài toán hồi quy (House Price)	6
3. ỨNG DỤNG 1 — DỰ ĐOÁN NGUY CƠ MẮC BỆNH TIỂU ĐƯỜNG.....	8
3.1 Mô tả bài toán.....	8
3.2 Bộ dữ liệu Kaggle.....	8
3.3 Kiểm tra và làm sạch dữ liệu	8
3.4 Biểu diễn dữ liệu (Data Representation)	8
3.5 Phân tích khám phá dữ liệu (EDA).....	10
3.6 Phân chia dữ liệu và mô hình	12
Bảng so sánh 5 mô hình phân lớp (tập Validation)	12
3.7 Đánh giá trên tập Test và lựa chọn mô hình.....	12
3.8 Đóng gói và triển khai	13
3.9 Mở rộng Đồ thị Tri thức Y tế & Mô hình Không gian Vector (Clinical GraphRAG)	13
4. ỨNG DỤNG 2 — DỰ ĐOÁN GIÁ NHÀ Ở VIỆT NAM	16
4.1 Mô tả bài toán.....	16
4.2 Bộ dữ liệu Kaggle.....	16
4.3 Làm sạch dữ liệu.....	16
4.4 Biểu diễn dữ liệu.....	16
4.5 Phân tích khám phá dữ liệu (EDA).....	17
4.6 Mô hình hồi quy	19
4.7 Đánh giá trên tập Test và lựa chọn mô hình.....	19
4.8 Đóng gói và triển khai	20
4.9 Mở rộng Đồ thị Tri thức Bất Động Sản & Mô hình Không gian Vector (Real Estate GraphRAG)	20
5. ỨNG DỤNG 3 — KHÁM PHÁ CẢM XÚC/SỞ THÍCH KHÁCH HÀNG TMĐT (SHOPEE).....	22
5.1 Mô tả bài toán.....	22
5.2 Bộ dữ liệu Kaggle.....	22
5.3 Làm sạch văn bản	23
5.4 Biểu diễn văn bản (Text Representation)	23
5.5 Phân tích khám phá dữ liệu (EDA).....	24
5.6 Mô hình phân lớp văn bản.....	26
5.7 Đánh giá trên tập Test và lựa chọn mô hình.....	26
5.8 Đóng gói và triển khai	27
5.9 Mở rộng Đồ thị Tri thức Trải nghiệm Khách hàng & GraphRAG TMĐT.....	27
6. SO SÁNH TỔNG HỢP BA HỆ THỐNG	30

Thảo luận so sánh	30
7. KIẾN TRÚC TRIỂN KHAI (WEB & MOBILE)	32
7.1 Dịch vụ Web (REST API)	32
7.2 Ứng dụng Mobile	32
7.3 Nguyên tắc chống rò rỉ dữ liệu khi triển khai	32
7.4 Minh chứng triển khai (Web & Mobile Evidence)	32
Minh chứng — Diabetes Prediction	32
Minh chứng — House Price Prediction	37
Minh chứng — Customer Behavior (Shopee Sentiment)	41
8. THẢO LUẬN (DISCUSSION QUESTIONS)	46
8.1 Câu hỏi chung cho cả 3 ứng dụng	46
8.2 Câu hỏi riêng cho ứng dụng E-commerce (Customer Behavior)	46
9. TÁI LẬP KẾT QUẢ (REPRODUCIBILITY)	47
10. KẾT LUẬN	49
10.1 Bài học chính	49
10.2 Thách thức kỹ thuật quan trọng nhất	49
10.3 Vấn đề biểu diễn dữ liệu quan trọng nhất	49
10.4 Bài học về Machine Learning	49
10.5 Bài học về triển khai	49
10.6 Đề xuất cải tiến trong tương lai	49

1. TÓM TẮT (EXECUTIVE SUMMARY)

Báo cáo trình bày quá trình xây dựng ba hệ thống học máy hoàn chỉnh theo đúng quy trình Data → Understand → Clean → Represent → Learn → Evaluate → Persist → Deploy, áp dụng cho ba bộ dữ liệu Kaggle thuộc ba dạng khác nhau: dữ liệu bảng số (tabular), dữ liệu bảng hỗn hợp số/danh mục, và dữ liệu văn bản tiếng Việt.

Ứng dụng	Bài toán	Biểu diễn chính	Mô hình tốt nhất	Kết quả chính
Diabetes Prediction	Phân lớp nhị phân	Feature vector/matrix $X \in \mathbb{R}^{(69057 \times 21)}$	Decision Tree	F1 = 0.7567 Accuracy = 0.7375
House Price Prediction	Hồi quy	Feature matrix (One-Hot + Scale) $X \in \mathbb{R}^{(75413 \times 307)}$	Random Forest Regressor	R2 = 0.4113 MAE = 22.65 tr/m2
Customer Behavior (Shopee Sentiment)	Phân lớp văn bản	TF-IDF matrix $X \in \mathbb{R}^{(6719 \times 10000)}$	Linear SVM	F1 = 0.9228 Accuracy = 0.9410

Cả ba ứng dụng đều được đóng gói thành Pipeline hoàn chỉnh (tiền xử lý + mô hình) bằng joblib, sẵn sàng để triển khai thông qua REST API và giao diện Web/Mobile mà không cần huấn luyện lại.

2. KẾT NỐI VỚI LECTURE 02: BIỂU DIỄN DỮ LIỆU

Theo nguyên lý cốt lõi của Lecture 02: Real-world data → Numerical representation → Computational model. Ba ứng dụng minh họa ba con đường biểu diễn khác nhau từ dữ liệu thô sang ma trận số:

Ứng dụng	Dữ liệu thô	Biểu diễn học máy	Shape mô hình nhận
Diabetes	CSV / bảng (22 cột)	Feature vector/matrix (chuẩn hóa Z-score)	$B \times 21$
House Price	CSV / bảng (13 cột, có chuỗi tiếng Việt)	Feature matrix (One-Hot Encoding + StandardScaler)	$B \times 307$
Customer Behavior	JSONL / văn bản bình luận	Ma trận TF-IDF (Tokens → Vector thưa)	$B \times 10000$

Trả lời các câu hỏi chung (áp dụng cho cả 3 ứng dụng)

- Một dòng (1 observation) đại diện cho: 1 bệnh nhân (Diabetes) / 1 tin đăng bất động sản (House) / 1 bình luận khách hàng (Customer).
- Một cột đại diện cho: 1 đặc trưng lâm sàng hoặc nhân khẩu học / 1 thuộc tính bất động sản / 1 từ hoặc cụm từ trong từ vựng TF-IDF.
- Cột mục tiêu: Diabetes_binary / Giá trên m2 / label cảm xúc (positive-negative).
- Đặc trưng danh mục (Quận, Huyện, Loại hình nhà, Giấy tờ pháp lý) được mã hóa bằng One-Hot Encoding; đặc trưng thứ bậc (GenHlth, Age, Education, Income) giữ nguyên do đã có thang đo tự nhiên; đặc trưng liên tục được chuẩn hóa bằng StandardScaler (Z-score).
- Chiều đặc trưng cuối cùng: 21 (Diabetes, không đổi vì toàn bộ đã là số), 307 (House, tăng do One-Hot mở rộng các danh mục Quận/Huyện), 10.000 (Customer, giới hạn kích thước từ vựng TF-IDF).

2.1 Bảng ký hiệu tham số chuẩn (Notation)

Trước khi đi vào chi tiết từng ứng dụng, bảng dưới đây tổng hợp toàn bộ ký hiệu tham số ma trận/vector được sử dụng xuyên suốt báo cáo (thống nhất với hệ ký hiệu trong Lecture 02 — Data Representation), kèm ý nghĩa chung và giá trị cụ thể đo được ở mỗi ứng dụng.

Ký hiệu	Tên đầy đủ	Ý nghĩa chung	Giá trị cụ thể trong 3 ứng dụng
N	Number of samples	Tổng số mẫu quan sát trong toàn bộ tập dữ liệu (số dòng của ma trận X).	Diabetes: $N=69.057$ · House: $N=75.413$ · Customer: $N=9.599$ (tổng), 6.719 (Train)
d	Feature dimension	Số chiều đặc trưng đầu vào sau khi biểu diễn số (số cột của ma trận X).	Diabetes: $d=21$ · House: $d=307$ (sau One-Hot) · Customer: không dùng d, thay bằng V
B	Batch size	Số mẫu xử lý cùng lúc trong 1 lượt gọi mô hình (huấn luyện theo lô hoặc suy luận thời gian thực).	Customer (Train batch): $B=6.719$ · Khi suy luận qua API: $B=1$
V	Vocabulary size	Tổng số từ/cụm từ (token) duy nhất trong từ điển do TfidfVectorizer học từ tập Train.	Customer: $V=10.000$ (giới hạn max_features)

Ký hiệu	Tên đầy đủ	Ý nghĩa chung	Giá trị cụ thể trong 3 ứng dụng
T	Sequence length	Số token trong 1 chuỗi văn bản sau tách từ — khái niệm tương ứng khi dùng biểu diễn embedding theo trình tự.	Không áp dụng trực tiếp cho TF-IDF (không giữ thứ tự từ); chỉ mang tính đối chiếu lý thuyết với Lecture 02
K	Number of classes	Số lớp đầu ra của bài toán phân lớp.	Diabetes: $K=2$ (0/1) · Customer: $K=2$ (positive/negative) · House: không áp dụng (bài toán hồi quy)
y	Target vector	Vector nhãn/giá trị mục tiêu, kích thước N — mỗi phần tử tương ứng 1-1 với 1 dòng của X.	Diabetes: $y \in \{0,1\}^N$ · House: $y \in \mathbb{R}^N$ (giá/m ² liên tục) · Customer: $y \in \{0,1\}^N$

2.2 Công thức và ý nghĩa các chỉ số đánh giá (Evaluation Metrics)

Phần này định nghĩa công thức toán học và ý nghĩa của toàn bộ chỉ số đánh giá được dùng xuyên suốt báo cáo, để tránh chỉ liệt kê con số mà không giải thích. Với TP/TN/FP/FN — lần lượt là True Positive (dự đoán dương tính đúng), True Negative (dự đoán âm tính đúng), False Positive (dự đoán dương tính sai — "báo động giả"), False Negative (dự đoán âm tính sai — "bỏ sót"). Với y_i = giá trị thực tế của mẫu thứ i, $\hat{y}_i$ = giá trị mô hình dự đoán, $\bar{y}$ = giá trị trung bình thực tế, N = số mẫu.

a) Chỉ số cho bài toán phân lớp (Diabetes, Customer Behavior)

Chỉ số	Công thức	Ý nghĩa trong ứng dụng
Accuracy	Accuracy = $(TP + TN) / (TP + TN + FP + FN)$	Tỷ lệ dự đoán đúng trên tổng số mẫu. Dễ hiểu nhưng có thể gây hiểu nhầm nếu dữ liệu mất cân bằng nhãn (VD: Customer Behavior lệch 62/38).
Precision	Precision = $TP / (TP + FP)$	Trong số các trường hợp mô hình dự đoán "dương tính" (có bệnh / tích cực), bao nhiêu % là đúng thật. Precision thấp nghĩa là nhiều "báo động giả".
Recall	Recall = $TP / (TP + FN)$	Trong số các trường hợp thực sự "dương tính", mô hình phát hiện được bao nhiêu %. Với Diabetes, Recall thấp đồng nghĩa bỏ sót ca bệnh thật — hậu quả nghiêm trọng hơn báo động giả.
F1-score	F1 = $2 \times (Precision \times Recall) / (Precision + Recall)$	Trung bình điều hòa (harmonic mean) giữa Precision và Recall — cân bằng cả hai, phù hợp khi dữ liệu mất cân bằng nhãn (dùng làm chỉ số chính để chọn mô hình ở cả Diabetes và Customer Behavior).
ROC-AUC	Diện tích dưới đường cong ROC (trục tung: True Positive Rate = Recall; trục hoành: False Positive Rate = FP/(FP+TN)), tính trên toàn bộ ngưỡng phân loại từ 0 đến 1	Đo khả năng phân tách 2 lớp của mô hình độc lập với việc chọn ngưỡng (threshold) cụ thể. AUC = 1: phân tách hoàn hảo; AUC = 0,5: tương đương đoán ngẫu nhiên.

b) Chỉ số cho bài toán hồi quy (House Price)

Chỉ số	Công thức	Ý nghĩa trong ứng dụng
MAE	$MAE = (1/N) \times \sum y_i - \hat{y}_i $	Sai số tuyệt đối trung bình — trung bình cộng độ lệch (không quan tâm dấu) giữa giá dự đoán và giá thực tế, cùng đơn vị với y (triệu VND/m ²) nên dễ diễn giải trực quan.
MSE	$MSE = (1/N) \times \sum (y_i - \hat{y}_i)^2$	Sai số bình phương trung bình — bình phương độ lệch trước khi lấy trung bình, phạt nặng các trường hợp dự đoán sai lệch lớn hơn so với MAE.
RMSE	$RMSE = \sqrt{MSE} = \sqrt{[(1/N) \times \sum (y_i - \hat{y}_i)^2]}$	Căn bậc hai của MSE — đưa đơn vị trở lại giống y (triệu VND/m ²), vẫn giữ đặc tính phạt nặng sai số lớn. $RMSE \geq MAE$ luôn đúng; chênh lệch giữa hai giá trị này càng lớn thì càng có nhiều dự đoán lệch xa (outlier error).
R ² (R-squared)	$R^2 = 1 - [\sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2]$	Tỷ lệ phương sai của y được mô hình giải thích được, so với việc chỉ đoán bằng giá trị trung bình $\bar{y}$. $R^2 = 1$: dự đoán hoàn hảo; $R^2 = 0$: không tốt hơn đoán trung bình; $R^2 = 0,4113$ (Random Forest) nghĩa là mô hình giải thích được ~41% biến thiên của giá nhà.

Lưu ý lựa chọn chỉ số chính theo bài toán: Diabetes ưu tiên Recall/F1 (tránh bỏ sót ca bệnh — hậu quả y tế của False Negative nghiêm trọng hơn False Positive); House Price ưu tiên R²/MAE (đo trực tiếp sai lệch giá trị dự đoán, đơn vị dễ diễn giải với người dùng cuối); Customer Behavior ưu tiên F1 (do nhãn lệch 62%/38%, Accuracy đơn thuần dễ gây hiểu nhầm).

3. ỨNG DỤNG 1 — DỰ ĐOÁN NGUY CƠ MẮC BỆNH TIỂU ĐƯỜNG

3.1 Mô tả bài toán

Mục tiêu: xây dựng hệ thống học máy tự động dự đoán nguy cơ mắc bệnh tiểu đường của một cá nhân dựa trên các chỉ số sức khỏe sinh học và thói quen sinh hoạt. Đây là bài toán phân lớp nhị phân có giám sát (Supervised Binary Classification): X = đặc trưng bệnh nhân, y = nhãn tiểu đường (0/1).

3.2 Bộ dữ liệu Kaggle

Thuộc tính	Chi tiết
Tên dataset	Diabetes Health Indicators Dataset (BRFSS 2015)
Nguồn / URL	kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset
Đơn vị thu thập gốc	CDC – Behavioral Risk Factor Surveillance System (BRFSS)
Số quan sát ban đầu (N)	70.692 dòng (bản 50-50 split đã cân bằng nhãn)
Số đặc trưng (d)	21 đặc trưng đầu vào
Biến mục tiêu	Diabetes binary (0: không bệnh, 1: có bệnh/nguy cơ cao)
Kiểu bài toán	Phân lớp nhị phân có giám sát
Mô tả 1 quan sát	Hồ sơ khảo sát 1 cá nhân: huyết áp, cholesterol, BMI, đột quy, bệnh tim, vận động, tuổi, thu nhập,...
Giấy phép	CC0: Public Domain

Ví dụ một số nhóm đặc trưng chính (21 cột đầu vào): nhị phân (HighBP, HighChol, Smoker, Stroke, PhysActivity, Sex,...), thứ bậc (GenHlth 1–5, Age 1–13, Education 1–6, Income 1–8), rời rạc (MentHlth, PhysHlth: 0–30 ngày) và liên tục (BMI: 12–98 kg/m²).

3.3 Kiểm tra và làm sạch dữ liệu

Bước	Kết quả	Xử lý
Giá trị khuyết thiếu	0 giá trị NaN trên toàn bộ 22 cột	Không cần xử lý
Bản ghi trùng lặp	1.635 dòng trùng lặp (2,31%)	Loại bỏ → còn 69.057 dòng
Giá trị không hợp lệ	0/22 cột vi phạm miền giá trị BRFSS	Không phát hiện lỗi
Ngoại lai (IQR)	BMI: 3,16%; MentHlth: 15,5%; PhysHlth: 15,38%	Giữ lại (phản ánh bệnh lý thực), chỉ loại BMI ngoài [10,100]


3.4 Biểu diễn dữ liệu (Data Representation)

Sau làm sạch: $N = 69.057$ bệnh nhân, $d = 21$ đặc trưng. Toàn bộ đặc trưng được chuẩn hóa Z-score (StandardScaler) trước khi đưa vào mô hình:

$$\mathbf{X} \in \mathbb{R}^{(69057 \times 21)}, \quad \mathbf{y} \in \mathbb{R}^{(69057)}$$

Giải thích tham số ma trận:

- **Trục 0 — $N = 69.057$:** Số dòng (số bệnh nhân) trong ma trận đặc trưng — mỗi dòng là hồ sơ khảo sát của 1 người tham gia BRFSS 2015, sau khi đã loại 1.635 bản ghi trùng lặp.
- **Trục 1 — $d = 21$:** Số cột (số đặc trưng đầu vào) — 21 chỉ số lâm sàng/nhân khẩu học đã được CDC mã hóa số sẵn (nhị phân, thứ bậc, rời rạc), không tính cột nhãn Diabetes_binary.
- **$\mathbf{y} \in \mathbb{R}^{(69057)}$:** Nhãn mục tiêu tương ứng 1-1 với từng dòng của $\mathbf{X}$, $y \in \{0, 1\}$ — biến ngẫu nhiên rời rạc thể hiện có/không mắc bệnh tiểu đường.



Hình 3.1 — Heatmap minh họa 25 dòng đầu của ma trận đặc trưng X sau chuẩn hóa Z-score.

Giải thích Biểu đồ Heatmap (Hình 3.1): Biểu đồ heatmap thể hiện giá trị đặc trưng của 25 bệnh nhân đầu tiên sau khi được chuẩn hóa Z-score. Trước khi tiền xử lý, các cột đặc trưng có thang đo rất khác nhau (ví dụ: BMI dao động từ 12 đến 98, trong khi HighBP chỉ nhận giá trị nhị phân 0 hoặc 1). Sau khi chuẩn hóa bằng StandardScaler(), toàn bộ các thuộc tính được đưa về cùng một phân phối có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1. Điều này giúp loại bỏ sự chênh lệch độ lớn giữa các biến, giúp các thuật toán nhạy cảm với khoảng cách (KNN, SVM, Logistic Regression) không bị thiên lệch và hội tụ nhanh hơn.

Ví dụ đối chiếu Biểu diễn Đặc trưng (Tabular Representation Example):

Thuộc tính (Feature)	Giá trị thô (Raw Value)	Giá trị số hóa (Model Input)
HighBP (Tăng huyết áp)	1 (Có)	1.00 (Nhị phân)
HighChol (Mỡ máu cao)	0 (Không)	0.00 (Nhị phân)
BMI (Chỉ số khối cơ thể)	32.0 (Béo phì)	0.85 (Z-score chuẩn hóa)
PhysActivity (Tập thể dục)	0 (Không)	0.00 (Nhị phân)
GenHlth (Đánh giá sức khỏe)	4 (Khá kém)	4.00 (Giữ nguyên thang thứ bậc)
Age (Nhóm tuổi)	9 (Tuổi 60-64)	9.00 (Giữ nguyên thang thứ bậc)

Giải thích Biểu đồ Heatmap (Hình 3.1): Biểu đồ heatmap thể hiện giá trị đặc trưng của 25 bệnh nhân đầu tiên sau khi được chuẩn hóa Z-score. Trước khi tiền xử lý, các cột đặc trưng có thang đo rất khác nhau (ví dụ: BMI dao động từ 12 đến 98, trong khi HighBP chỉ nhận giá trị nhị phân 0 hoặc 1). Sau khi chuẩn hóa bằng StandardScaler(), toàn bộ các thuộc tính được đưa về cùng một phân phối có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1. Điều này giúp loại bỏ sự chênh lệch độ lớn giữa các biến, giúp các thuật toán nhạy cảm với khoảng cách (KNN, SVM, Logistic Regression) không bị thiên lệch và hội tụ nhanh hơn.

Ví dụ đối chiếu Biểu diễn Đặc trưng (Tabular Representation Example):

Thuộc tính (Feature)	Giá trị thô (Raw Value)	Giá trị số hóa (Model Input)
HighBP (Tăng huyết áp)	1 (Có)	1.00 (Nhị phân)
HighChol (Mỡ máu cao)	0 (Không)	0.00 (Nhị phân)
BMI (Chỉ số khối cơ thể)	32.0 (Béo phì)	0.85 (Z-score chuẩn hóa)
PhysActivity (Tập thể dục)	0 (Không)	0.00 (Nhị phân)
GenHlth (Đánh giá sức khỏe)	4 (Khá kém)	4.00 (Giữ nguyên thang thứ bậc)

Age (Nhóm tuổi)	9 (Tuổi 60-64)	9.00 (Giữ nguyên thang thứ bậc)
-----------------	----------------	---------------------------------

Giải thích Biểu đồ Heatmap (Hình 3.1): Biểu đồ heatmap thể hiện giá trị đặc trưng của 25 bệnh nhân đầu tiên sau khi được chuẩn hóa Z-score. Trước khi tiền xử lý, các cột đặc trưng có thang đo rất khác nhau (ví dụ: BMI dao động từ 12 đến 98, trong khi HighBP chỉ nhận giá trị nhị phân 0 hoặc 1). Sau khi chuẩn hóa bằng StandardScaler(), toàn bộ các thuộc tính được đưa về cùng một phân phối có giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1. Điều này giúp loại bỏ sự chênh lệch độ lớn giữa các biến, giúp các thuật toán nhạy cảm với khoảng cách (KNN, SVM, Logistic Regression) không bị thiên lệch và hội tụ nhanh hơn.


Ví dụ đối chiếu Biểu diễn Đặc trưng (Tabular Representation Example):

Thuộc tính (Feature)	Giá trị thô (Raw Value)	Giá trị số hóa (Model Input)
HighBP (Tăng huyết áp)	1 (Có)	1.00 (Nhị phân)
HighChol (Mỡ máu cao)	0 (Không)	0.00 (Nhị phân)
BMI (Chỉ số khối cơ thể)	32.0 (Béo phì)	0.85 (Z-score chuẩn hóa)
PhysActivity (Tập thể dục)	0 (Không)	0.00 (Nhị phân)
GenHlth (Đánh giá sức khỏe)	4 (Khá kém)	4.00 (Giữ nguyên thang thứ bậc)

Age (Nhóm tuổi)	9 (Tuổi 60-64)	9.00 (Giữ nguyên thang thứ bậc)
-----------------	----------------	---------------------------------

Không cần Feature Engineering bổ sung: 21 đặc trưng gốc do CDC mã hóa số học sẵn (nhị phân 0/1 và thang thứ bậc) đã có ý nghĩa lâm sàng rõ ràng, việc tạo đặc trưng tổ hợp nhân tạo có thể làm giảm khả năng giải thích với bác sĩ.

3.5 Phân tích khám phá dữ liệu (EDA)



Hình 3.2 — (1) Phân bố nhân mục tiêu; (2) Phân bố BMI theo nhóm bệnh; (3) Tỷ lệ mắc bệnh theo huyết áp; (4) Ma trận tương quan top đặc trưng.

Giải thích Chi tiết các Biểu đồ EDA (Hình 3.2):

- (1) Biểu đồ phân bố nhãn mục tiêu: Thể hiện tỷ lệ cân bằng lý tưởng (50.3% không bệnh / 49.7% có bệnh). Đây là kết quả của việc áp dụng kỹ thuật lấy mẫu đồng đều, giúp loại bỏ hoàn toàn vấn đề mất cân bằng nhóm (class imbalance) thường thấy trong y tế, cho phép sử dụng chỉ số Accuracy làm thước đo so sánh khách quan bên cạnh F1-Score.
- (2) Biểu đồ phân bố BMI: Phân phối BMI của nhóm có bệnh (đường màu hồng) bị lệch hẳn sang bên phải với giá trị trung bình là 31.9 kg/m² (ngưỡng béo phì độ 1) so với 27.7 kg/m² ở nhóm bình thường. Điều này chứng minh BMI là một đặc trưng mang tính phân tách cực kỳ mạnh mẽ.
- (3) Biểu đồ tỷ lệ theo huyết áp: Hơn 75% người bị cao huyết áp mắc bệnh tiểu đường, trong khi ở nhóm huyết áp bình thường tỷ lệ này chỉ dưới 25%. Sự đồng biến này phù hợp với cơ chế bệnh học của hội chứng chuyển hóa.
- (4) Ma trận tương quan: Cho thấy GenHlth (Sức khỏe tự đánh giá), HighBP (Tăng huyết áp) và BMI là ba đặc trưng có hệ số tương quan tuyến tính Pearson cao nhất với nhãn mục tiêu (lần lượt là 0.40, 0.38, 0.29).

Giải thích Chi tiết các Biểu đồ EDA (Hình 3.2):

- (1) Biểu đồ phân bố nhãn mục tiêu: Thể hiện tỷ lệ cân bằng lý tưởng (50.3% không bệnh / 49.7% có bệnh). Đây là kết quả của việc áp dụng kỹ thuật lấy mẫu đồng đều, giúp loại bỏ hoàn toàn vấn đề mất cân bằng nhóm (class imbalance) thường thấy trong y tế, cho phép sử dụng chỉ số Accuracy làm thước đo so sánh khách quan bên cạnh F1-Score.
- (2) Biểu đồ phân bố BMI: Phân phối BMI của nhóm có bệnh (đường màu hồng) bị lệch hẳn sang bên phải với giá trị trung bình là 31.9 kg/m² (ngưỡng béo phì độ 1) so với 27.7 kg/m² ở nhóm bình thường. Điều này chứng minh BMI là một đặc trưng mang tính phân tách cực kỳ mạnh mẽ.
- (3) Biểu đồ tỷ lệ theo huyết áp: Hơn 75% người bị cao huyết áp mắc bệnh tiểu đường, trong khi ở nhóm huyết áp bình thường tỷ lệ này chỉ dưới 25%. Sự đồng biến này phù hợp với cơ chế bệnh học của hội chứng chuyển hóa.
- (4) Ma trận tương quan: Cho thấy GenHlth (Sức khỏe tự đánh giá), HighBP (Tăng huyết áp) và BMI là ba đặc trưng có hệ số tương quan tuyến tính Pearson cao nhất với nhãn mục tiêu (lần lượt là 0.40, 0.38, 0.29).

Giải thích Chi tiết các Biểu đồ EDA (Hình 3.2):

- (1) Biểu đồ phân bố nhãn mục tiêu: Thể hiện tỷ lệ cân bằng lý tưởng (50.3% không bệnh / 49.7% có bệnh). Đây là kết quả của việc áp dụng kỹ thuật lấy mẫu đồng đều, giúp loại bỏ hoàn toàn vấn đề mất cân bằng nhóm (class imbalance) thường thấy trong y tế, cho phép sử dụng chỉ số Accuracy làm thước đo so sánh khách quan bên cạnh F1-Score.
- (2) Biểu đồ phân bố BMI: Phân phối BMI của nhóm có bệnh (đường màu hồng) bị lệch hẳn sang bên phải với giá trị trung bình là 31.9 kg/m² (ngưỡng béo phì độ 1) so với 27.7 kg/m² ở nhóm bình thường. Điều này chứng minh BMI là một đặc trưng mang tính phân tách cực kỳ mạnh mẽ.
- (3) Biểu đồ tỷ lệ theo huyết áp: Hơn 75% người bị cao huyết áp mắc bệnh tiểu đường, trong khi ở nhóm huyết áp bình thường tỷ lệ này chỉ dưới 25%. Sự đồng biến này phù hợp với cơ chế bệnh học của hội chứng chuyển hóa.
- (4) Ma trận tương quan: Cho thấy GenHlth (Sức khỏe tự đánh giá), HighBP (Tăng huyết áp) và BMI là ba đặc trưng có hệ số tương quan tuyến tính Pearson cao nhất với nhãn mục tiêu (lần lượt là 0.40, 0.38, 0.29).

- Quan sát: Tập dữ liệu cân bằng (50,3% không bệnh / 49,7% có bệnh) → Accuracy và F1-score đều đáng tin cậy.
- Quan sát: BMI trung bình nhóm có bệnh là 31,9 kg/m² so với 27,7 kg/m² ở nhóm không bệnh → Tình trạng thừa cân/béo phì có mối liên hệ thống kê thuận mạnh mẽ với nguy cơ mắc bệnh trong tập dữ liệu (phù hợp với y văn ADA rằng mô mỡ tích tụ liên quan mật thiết đến tình trạng đề kháng insulin), biến BMI là đặc trưng phân tách mạnh cho các mô hình học máy.

- Quan sát: >75% người tăng huyết áp có nguy cơ/tiểu đường, so với <25% ở nhóm huyết áp bình thường → Huyết áp cao và rối loạn chuyển hóa glucose có mối liên hệ thống kê chặt chẽ trong hội chứng chuyển hóa, biến HighBP có trọng số phân loại lớn.
- Tương quan cao nhất với nhãn: GenHlth (0,40), HighBP (0,38), BMI (0,29), DiffWalk (0,27), Age (0,28).

3.6 Phân chia dữ liệu và mô hình

Chiến lược: 70% Train / 15% Validation / 15% Test, có phân tầng (Stratified) theo nhãn để giữ tỉ lệ lớp đồng đều.

Baseline (DummyClassifier – đoán mù lớp đa số): Accuracy = 0,5083, F1-score = 0,6740 (Recall = 1.0 nhưng không phân biệt được lớp âm tính).


Bảng so sánh 5 mô hình phân lớp (tập Validation)

Mô hình	Accuracy	F1-score	ROC-AUC	Thời gian (s)
Cây quyết định (Decision Tree)	0,7341	0,7565	0,8073	0,09
Máy vector hỗ trợ (Linear SVM)	0,7427	0,7543	0,8179	0,13
Hồi quy Logistic	0,7424	0,7526	0,8182	0,03
Rừng ngẫu nhiên (Random Forest)	0,7291	0,7437	0,7990	0,92
KNN (k=7)	0,7173	0,7295	0,7764	0,00

3.7 Đánh giá trên tập Test và lựa chọn mô hình

Mô hình được chọn triển khai: Decision Tree — đạt F1-score cao nhất trên Test.

Chỉ số	Giá trị (Test)
Accuracy	0,7375
Precision	0,7154
Recall	0,8030
F1-score	0,7567
ROC-AUC	0,8072



Hình 3.3 — Ma trận nhầm lẫn của mô hình Decision Tree trên tập Test.

Phân tích Ma trận Nhầm lẫn (Confusion Matrix - Hình 3.3): Ma trận nhầm lẫn của mô hình Cây Quyết định trên tập Test độc lập (N = 10.598 ca) cho thấy khả năng nhận diện cân bằng. Mô hình phân loại đúng 3.966 ca âm tính (True Negative) và 3.850 ca dương tính (True Positive). Trong y tế, chỉ số quan trọng nhất là hạn chế bỏ sót ca bệnh. Với tỷ lệ Recall đạt 80.30%, mô hình chỉ bỏ sót

944 ca (False Negative) trên tổng số người bệnh thực tế. Đây là mức chấp nhận được đối với một công cụ sàng lọc cộng đồng ban đầu bằng bảng hỏi, giúp cảnh báo kịp thời cho người dùng đi xét nghiệm lâm sàng chuyên sâu.

Phân tích Ma trận Nhầm lẫn (Confusion Matrix - Hình 3.3): Ma trận nhầm lẫn của mô hình Cây Quyết định trên tập Test độc lập (N = 10.598 ca) cho thấy khả năng nhận diện cân bằng. Mô hình phân loại đúng 3.966 ca âm tính (True Negative) và 3.850 ca dương tính (True Positive). Trong y tế, chỉ số quan trọng nhất là hạn chế bỏ sót ca bệnh. Với tỷ lệ Recall đạt 80.30%, mô hình chỉ bỏ sót 944 ca (False Negative) trên tổng số người bệnh thực tế. Đây là mức chấp nhận được đối với một công cụ sàng lọc cộng đồng ban đầu bằng bảng hỏi, giúp cảnh báo kịp thời cho người dùng đi xét nghiệm lâm sàng chuyên sâu.

Phân tích Ma trận Nhầm lẫn (Confusion Matrix - Hình 3.3): Ma trận nhầm lẫn của mô hình Cây Quyết định trên tập Test độc lập (N = 10.598 ca) cho thấy khả năng nhận diện cân bằng. Mô hình phân loại đúng 3.966 ca âm tính (True Negative) và 3.850 ca dương tính (True Positive). Trong y tế, chỉ số quan trọng nhất là hạn chế bỏ sót ca bệnh. Với tỷ lệ Recall đạt 80.30%, mô hình chỉ bỏ sót 944 ca (False Negative) trên tổng số người bệnh thực tế. Đây là mức chấp nhận được đối với một công cụ sàng lọc cộng đồng ban đầu bằng bảng hỏi, giúp cảnh báo kịp thời cho người dùng đi xét nghiệm lâm sàng chuyên sâu.

Biện luận lựa chọn (5 tiêu chí): (1) Hiệu năng: F1 cao nhất (0,7567), Recall 0,8030 giúp giảm bỏ sót ca bệnh; (2) Khả năng giải thích: cây quyết định trực quan, bác sĩ có thể theo dõi luật quyết định; (3) Chi phí tính toán: huấn luyện nhanh (0,09s); (4) Độ bền vững: ổn định qua Validation/Test; (5) Ràng buộc triển khai: dễ đóng gói, suy luận tức thời, phù hợp API thời gian thực.

3.8 Đóng gói và triển khai

Pipeline hoàn chỉnh (StandardScaler + Decision Tree) được lưu bằng joblib tại models/diabetes_pipeline.joblib, kèm theo metadata (tên đặc trưng, mô hình được chọn, chỉ số đánh giá) để đảm bảo quá trình suy luận (inference) sử dụng đúng phép biến đổi đã học từ tập Train, tránh rò rỉ dữ liệu (data leakage).

Dịch vụ Web (FastAPI) cung cấp endpoint POST /predict nhận 21 đặc trưng đầu vào (JSON) và trả về {"prediction": 0/1, "confidence": 0.xx}. Giao diện Mobile gọi cùng API này để hiển thị kết quả cho người dùng cuối.

3.9 Mở rộng Đồ thị Tri thức Y tế & Mô hình Không gian Vector (Clinical GraphRAG)

Nhằm nâng cao khả năng giải thích và hỗ trợ ra quyết định lâm sàng, hệ thống tích hợp một Đồ thị Tri thức Y tế (Clinical Knowledge Graph) gồm 15 Nodes và 20 Edges được đồng bộ trực tiếp từ API hệ thống. Tri thức này liên kết các chỉ số sinh học, lối sống, nguy cơ mắc bệnh và các biến chứng lâm sàng đa cơ quan.

Bảng 3.2 — Chi tiết các thực thể (Nodes) trong Đồ thị Tri thức Y tế:

Mã Node (ID)	Tên thực thể (Label)	Phân nhóm (Category)	Mô tả bệnh học / Ý nghĩa lâm sàng
Patient	Hồ sơ Bệnh nhân	Thực thể Gốc (Root Entity)	Nút trung tâm đại diện cho cá thể bệnh nhân đang được khảo sát 21 chỉ số lâm sàng.
HighBP	Tăng Huyết Áp	Yếu tố Nguy cơ (Risk Factor)	Áp lực dòng máu cao làm xơ cứng vi mạch, tổn thương tế bào nội mô và thúc đẩy đề kháng insulin (Trọng số rủi ro: 0.72).
HighChol	Mỡ Máu Cao (Hyperlipidemia)	Yếu tố Nguy cơ (Risk Factor)	Nồng độ cholesterol xấu (LDL-C) và triglyceride cao gây

			lắng đọng mảng xơ vữa và rối loạn chuyển hóa lipid (Trọng số rủi ro: 0.65).
BMI	Chỉ số Khối cơ thể (BMI)	Yếu tố Nguy cơ Cốt lõi	Mô mỡ tích tụ (đặc biệt mỡ nội tạng) tiết cytokine gây viêm và ức chế trực tiếp thụ thể Insulin tại mô cơ và gan (Trọng số rủi ro: 0.78).
Smoker	Hút Thuốc Lá	Yếu tố Hành vi Nguy cơ	Chất độc nicotin kích thích thần kinh giao cảm, làm tăng tiết cortisol và catecholamine gây tăng đề kháng insulin (Trọng số rủi ro: 0.48).
Stroke	Đột Quỵ Não	Bệnh Đồng Mạch & Biến chứng	Biến chứng mạch máu lớn do tổn thương tuần hoàn não, có mối tương quan bệnh học 2 chiều với Đái tháo đường.
HeartDiseaseorAttack	Bệnh Tim Mạch & Nhồi Máu Cơ Tim	Bệnh Đồng Mạch & Biến chứng	Đường huyết cao làm xơ cứng mạch vành tim. Hơn 70% bệnh nhân tiểu đường tử vong do biến chứng tim mạch.
DiffWalk	Khó Khăn Vận Động / Đi Lại	Biến chứng Thần kinh & Cơ xương	Hậu quả của biến chứng bàn chân đái tháo đường, viêm đa dây thần kinh ngoại biên hoặc thoái hóa khớp do béo phì.
PhysActivity	Hoạt Động Thể Lực (≥ 150 p/tuần)	Yếu tố Bảo vệ (Protective Factor)	Cơ cơ kích hoạt con đường bắt giữ glucose không phụ thuộc insulin thông qua AMPK, tăng nhạy cảm insulin lên 40%.
Fruits	Ăn Hoa Quả Thường Xuyên	Yếu tố Bảo vệ (Protective Factor)	Cung cấp chất chống oxy hóa (Polyphenols, Vitamin C) làm giảm stress oxy hóa tại tế bào beta đảo tụy.
Veggies	Ăn Rau Xanh Đầy Đủ	Yếu tố Bảo vệ (Protective Factor)	Chất xơ hòa tan làm chậm quá trình hấp thu carbohydrate tại

			ruột non, ngăn ngừa đỉnh tăng đường huyết đột ngột sau ăn.
GenHlth	Sức Khỏe Tổng Quát (Thang 1-5)	Chỉ số Đánh giá Cá nhân	Chỉ báo phản ánh gánh nặng bệnh tật tổng thể, tương quan mạnh mẽ với tỷ lệ mắc bệnh mạn tính.
Age	Nhóm Tuổi (Thang 1-13)	Chỉ số Nhân khẩu học	Quá trình lão hóa làm suy giảm tự nhiên chức năng tiết insulin của tế bào beta và tăng tỷ lệ mỡ nội tạng.
Diabetes	Bệnh Đái Tháo Đường (Diabetes)	Kết luận Lâm sàng (Outcome)	Bệnh lý rối loạn chuyển hóa carbohydrate đặc trưng bởi đường huyết mạn tính cao do thiếu hoặc kháng insulin.
NoDiabetes	Không Mắc Bệnh (Khỏe mạnh)	Kết luận Lâm sàng (Outcome)	Trạng thái chuyển hóa glucose bình thường, các cơ chế điều hòa nội môi được duy trì ổn định.

Bảng 3.3 — Chi tiết các quan hệ (Edges) liên kết lâm sàng:

Thực thể nguồn (Source)	Mối quan hệ (Relation)	Thực thể đích (Target)	Trọng số (Weight) / Hướng tác động
Patient	HAS_CONDITION	HighBP	1.0
Patient	HAS_CONDITION	HighChol	1.0
Patient	HAS_ATTRIBUTE	BMI	1.0
Patient	HAS_BEHAVIOR	Smoker	1.0
Patient	HAS_BEHAVIOR	PhysActivity	1.0
Patient	HAS_ATTRIBUTE	Age	1.0
HighBP	INCREASES_RISK	Diabetes	0.72
HighChol	INCREASES_RISK	Diabetes	0.65
BMI	INCREASES_RISK	Diabetes	0.78
Smoker	INCREASES_RISK	Diabetes	0.48
Stroke	COMORBIDITY	Diabetes	0.55
HeartDiseaseorAttack	COMORBIDITY	Diabetes	0.6
Age	INCREASES_RISK	Diabetes	0.55
GenHlth	INDICATES	Diabetes	0.68
PhysActivity	REDUCES_RISK	Diabetes	0.45
Fruits	REDUCES_RISK	Diabetes	0.3
Veggies	REDUCES_RISK	Diabetes	0.28
Diabetes	LEADS_TO	Stroke	0.4
Diabetes	LEADS_TO	HeartDiseaseorAttack	0.45
Diabetes	LEADS_TO	DiffWalk	0.35

Cơ chế truy vấn GraphRAG: Tri thức từ đồ thị được chuyển hóa thành các đoạn văn bản ngữ nghĩa và lưu trữ trong Không gian Vector (Vector Space Model) bằng kỹ thuật TF-IDF và Cosine Similarity. Khi người dùng truy cập, hệ thống GraphRAG sẽ thực hiện tìm kiếm tương đồng trên các mô tả node và quan hệ để trích xuất luật y khoa liên quan (ví dụ: béo phì liên kết với biến chứng

võng mạc và suy thận) đưa vào làm ngữ cảnh nền (context) cho Groq LLM, đảm bảo câu trả lời có tính xác thực y khoa cao nhất.

4. ỨNG DỤNG 2 — DỰ ĐOÁN GIÁ NHÀ Ở VIỆT NAM

4.1 Mô tả bài toán

Mục tiêu: xây dựng hệ thống học máy dự đoán đơn giá trên mỗi mét vuông (triệu VND/m²) của bất động sản nhà ở Việt Nam dựa trên vị trí, loại hình nhà, pháp lý và diện tích. Đây là bài toán hồi quy (Regression): X = đặc trưng bất động sản, y = giá/m². Khác với Diabetes (phân lớp — dự đoán nhãn rời rạc), bài toán này dự đoán một giá trị liên tục nên cần các thang đo lỗi khác (MAE, RMSE, R²) thay vì Accuracy/F1.

4.2 Bộ dữ liệu Kaggle

Thuộc tính	Chi tiết
Tên dataset	Vietnam Housing Dataset
Nguồn / URL	kaggle.com/datasets/ladcvn/vietnam-housing-dataset-hanoi
Đơn vị thu thập	Các trang tin rao vặt / sàn giao dịch BĐS trực tuyến tại Việt Nam
Số quan sát ban đầu (N)	82.497 tin đăng
Số cột ban đầu	13 cột
Biến mục tiêu	Giá/m ² (triệu VND/m ² , số thực liên tục)
Kiểu bài toán	Hồi quy có giám sát
Mô tả 1 quan sát	1 tin rao bán: Quận, Huyện, Loại hình nhà, Giấy tờ pháp lý, Số tầng, Số phòng ngủ, Diện tích, Dài, Rộng, Đơn giá
Giấy phép	Open Data License

4.3 Làm sạch dữ liệu

- Bóc tách số thực từ chuỗi định dạng tiếng Việt (VD: "86,96 triệu/m²" → 86.96) cho cột giá và các cột số (Số tầng, Số phòng ngủ, Diện tích, Dài, Rộng).
- Loại bỏ cột ID/ngày tháng/địa chỉ chi tiết (Unnamed: 0, Ngày, Địa chỉ) để tránh rò rỉ thông tin định danh.
- Loại 5.528 dòng trùng lặp; không có giá hoặc diện tích ≤ 0 (0 lỗi Invalid-value).
- Ngoại lai: cắt theo phân vị 1%–99% của giá/m² (21,90 – 385,01 tr/m²), loại 1.540 tin đăng ảo/cực đoan → còn 75.413 tin sạch.

4.4 Biểu diễn dữ liệu


Các biến danh mục (Quận, Huyện, Loại hình nhà, Giấy tờ pháp lý) được mã hóa One-Hot Encoding; các biến số (Số tầng, Số phòng ngủ, Diện tích, Dài, Rộng) được impute giá trị thiếu bằng median rồi chuẩn hóa StandardScaler. Sau biến đổi:

$$\mathbf{X} \in \mathbb{R}^{(75413 \times 307)}, \quad \mathbf{y} \in \mathbb{R}^{(75413)}$$

Giải thích tham số ma trận:

- **Trục 0 — $N = 75.413$:** Số dòng (số tin đăng bất động sản) còn lại sau khi loại 5.528 dòng trùng lặp và 1.540 tin đăng ngoại lai cực đoan (giá/m² nằm ngoài khoảng phân vị 1%–99%).
- **Trục 1 — $d = 307$:** Số cột sau biến đổi — tăng từ 9 cột gốc (Loại hình nhà, Giấy tờ pháp lý, Số tầng, Số phòng ngủ, Diện tích, Dài, Rộng, Quận, Huyện) lên 307 chiều, do One-Hot Encoding mở rộng riêng từng giá trị Quận/Huyện thành 1 cột nhị phân độc lập; 5 biến số (Số tầng, Số phòng ngủ, Diện tích, Dài, Rộng) giữ nguyên 1 cột/biến sau chuẩn hóa Z-score.

- $y \in \mathbb{R}^{(75413)}$: Giá trị mục tiêu liên tục (đơn vị: triệu VND/m²) tương ứng 1-1 với từng dòng của X .




Hình 4.1 — Heatmap minh họa ma trận đặc trưng X sau One-Hot Encoding + chuẩn hóa.

Giải thích Ma trận Đặc trưng BĐS (Hình 4.1): Do tập dữ liệu chứa các biến danh mục có số lượng giá trị rất lớn như Quận (30 quận/huyện) và Huyện/Xã, việc áp dụng One-Hot Encoding làm phình to số lượng cột từ 9 cột ban đầu lên thành 307 cột đặc trưng. Heatmap thể hiện cấu trúc ma trận thưa (Sparse Matrix), nơi phần lớn các ô có giá trị bằng 0 (màu tối) và chỉ các thuộc tính vị trí tương ứng của ngôi nhà nhận giá trị bằng 1 (ô sáng). Việc chuẩn hóa Z-score cho các biến kích thước (Diện tích, Dài, Rộng) giúp mô hình không bị lệch trọng số bởi đơn vị đo lường.

Giải thích Ma trận Đặc trưng BĐS (Hình 4.1): Do tập dữ liệu chứa các biến danh mục có số lượng giá trị rất lớn như Quận (30 quận/huyện) và Huyện/Xã, việc áp dụng One-Hot Encoding làm phình to số lượng cột từ 9 cột ban đầu lên thành 307 cột đặc trưng. Heatmap thể hiện cấu trúc ma trận thưa (Sparse Matrix), nơi phần lớn các ô có giá trị bằng 0 (màu tối) và chỉ các thuộc tính vị trí tương ứng của ngôi nhà nhận giá trị bằng 1 (ô sáng). Việc chuẩn hóa Z-score cho các biến kích thước (Diện tích, Dài, Rộng) giúp mô hình không bị lệch trọng số bởi đơn vị đo lường.

Giải thích Ma trận Đặc trưng BĐS (Hình 4.1): Do tập dữ liệu chứa các biến danh mục có số lượng giá trị rất lớn như Quận (30 quận/huyện) và Huyện/Xã, việc áp dụng One-Hot Encoding làm phình to số lượng cột từ 9 cột ban đầu lên thành 307 cột đặc trưng. Heatmap thể hiện cấu trúc ma trận thưa (Sparse Matrix), nơi phần lớn các ô có giá trị bằng 0 (màu tối) và chỉ các thuộc tính vị trí tương ứng của ngôi nhà nhận giá trị bằng 1 (ô sáng). Việc chuẩn hóa Z-score cho các biến kích thước (Diện tích, Dài, Rộng) giúp mô hình không bị lệch trọng số bởi đơn vị đo lường. Chiều đặc trưng tăng từ 9 cột gốc (không tính target) lên 307 chiều do One-Hot Encoding mở rộng số lượng Quận/Huyện thành các cột nhị phân riêng biệt — một minh chứng trực tiếp cho nguyên lý "biểu diễn danh mục" trong Lecture 02.

4.5 Phân tích khám phá dữ liệu (EDA)



Hình 4.2 — Phân bố giá, quan hệ diện tích–giá, phân bố theo khu vực và ma trận tương quan.

Giải thích Kết quả Khám phá Dữ liệu BĐS (Hình 4.2):

- Phân bố đơn giá/m²: Cho thấy phân phối lệch phải cực kỳ nặng (Right-skewed / Log-normal). Phần lớn các căn nhà tập trung ở phân khúc trung cấp từ 50 đến 120 triệu/m², trong khi xuất hiện đuôi dài đại diện cho phân khúc siêu sang (>300 triệu/m²) ở các quận trung tâm như Hoàn Kiếm, Hai Bà Trưng.
- Quan hệ Diện tích - Giá: Biểu đồ phân tán (Scatter Plot) thể hiện tính dị phương sai (Heteroscedasticity). Khi diện tích tăng lên, mức độ biến động của đơn giá cũng rộng hơn rõ rệt. Những căn nhà có diện tích lớn ở mặt phố có giá trị thương mại cộng thêm rất cao.
- Phân bố theo Khu vực: Giá nhà ở các quận lõi đô thị (Ba Đình, Đống Đa) vượt trội hoàn toàn so với các khu vực ven đô (Đông Anh, Gia Lâm, Hoài Đức), chứng minh vị trí là yếu tố tiên quyết quyết định giá trị BĐS.

Giải thích Kết quả Khám phá Dữ liệu BĐS (Hình 4.2):

- Phân bố đơn giá/m²: Cho thấy phân phối lệch phải cực kỳ nặng (Right-skewed / Log-normal). Phần lớn các căn nhà tập trung ở phân khúc trung cấp từ 50 đến 120 triệu/m², trong khi xuất hiện đuôi dài đại diện cho phân khúc siêu sang (>300 triệu/m²) ở các quận trung tâm như Hoàn Kiếm, Hai Bà Trưng.
- Quan hệ Diện tích - Giá: Biểu đồ phân tán (Scatter Plot) thể hiện tính dị phương sai (Heteroscedasticity). Khi diện tích tăng lên, mức độ biến động của đơn giá cũng rộng hơn rõ rệt. Những căn nhà có diện tích lớn ở mặt phố có giá trị thương mại cộng thêm rất cao.
- Phân bố theo Khu vực: Giá nhà ở các quận lõi đô thị (Ba Đình, Đống Đa) vượt trội hoàn toàn so với các khu vực ven đô (Đông Anh, Gia Lâm, Hoài Đức), chứng minh vị trí là yếu tố tiên quyết quyết định giá trị BĐS.

Giải thích Kết quả Khám phá Dữ liệu BĐS (Hình 4.2):

- Phân bố đơn giá/m²: Cho thấy phân phối lệch phải cực kỳ nặng (Right-skewed / Log-normal). Phần lớn các căn nhà tập trung ở phân khúc trung cấp từ 50 đến 120 triệu/m², trong khi xuất

hiện đuôi dài đại diện cho phân khúc siêu sang (>300 triệu/m²) ở các quận trung tâm như Hoàn Kiếm, Hai Bà Trưng.

- Quan hệ Diện tích - Giá: Biểu đồ phân tán (Scatter Plot) thể hiện tính dị phương sai (Heteroscedasticity). Khi diện tích tăng lên, mức độ biến động của đơn giá cũng rộng hơn rõ rệt. Những căn nhà có diện tích lớn ở mặt phố có giá trị thương mại cộng thêm rất cao.
- Phân bố theo Khu vực: Giá nhà ở các quận lõi đô thị (Ba Đình, Đống Đa) vượt trội hoàn toàn so với các khu vực ven đô (Đông Anh, Gia Lâm, Hoài Đức), chứng minh vị trí là yếu tố tiên quyết quyết định giá trị BĐS.

4.6 Mô hình hồi quy


Baseline (DummyRegressor – dự đoán trung bình): MAE = 30,68 tr/m², RMSE = 46,38, R² ≈ 0. Năm mô hình hồi quy được huấn luyện và so sánh trên Validation:

Mô hình	MAE (tr/m ²)	RMSE (tr/m ²)	R ² Score	Thời gian (s)
Rừng ngẫu nhiên (Random Forest)	23,14	36,25	0,3890	32,0
Tăng cường độ dốc (Gradient Boosting)	24,58	36,71	0,3735	62,3
Cây quyết định (Decision Tree)	24,87	38,00	0,3285	1,4
Hồi quy Ridge	25,40	37,24	0,3551	0,2
Hồi quy Tuyến tính	25,41	37,26	0,3545	0,8

4.7 Đánh giá trên tập Test và lựa chọn mô hình

Mô hình được chọn: Random Forest Regressor — đạt R² và MAE tốt nhất.

Chỉ số	Giá trị (Test)
MAE	22,65 triệu VND/m ²
RMSE	35,78 triệu VND/m ²
R ² Score	0,4113



Hình 4.3 — Biểu đồ so sánh Giá thực tế và Giá dự đoán (Random Forest Regressor).

Phân tích Kết quả Dự báo Hồi quy (Hình 4.3): Biểu đồ phân tán so sánh giữa Giá thực tế (Trục X) và Giá dự đoán (Trục Y) cho thấy mô hình Random Forest Regressor dự báo rất sát (các điểm tập trung quanh đường chéo 45 độ) ở phân khúc giá từ 30 triệu đến 150 triệu/m². Tuy nhiên, ở phân khúc siêu cao cấp (>200 triệu/m²), mô hình xuất hiện xu hướng dự báo thấp hơn thực tế (Underestimation). Lý do là vì ở phân khúc này, giá trị nhà đất bị chi phối nặng nề bởi các yếu tố định tính, cảm xúc cá nhân, độ độc bản hoặc phong thủy mà tập dữ liệu rao bán thô không thể ghi nhận được.

Phân tích Kết quả Dự báo Hồi quy (Hình 4.3): Biểu đồ phân tán so sánh giữa Giá thực tế (Trục X) và Giá dự đoán (Trục Y) cho thấy mô hình Random Forest Regressor dự báo rất sát (các điểm tập trung quanh đường chéo 45 độ) ở phân khúc giá từ 30 triệu đến 150 triệu/m². Tuy nhiên, ở phân

khúc siêu cao cấp (>200 triệu/m²), mô hình xuất hiện xu hướng dự báo thấp hơn thực tế (Underestimation). Lý do là vì ở phân khúc này, giá trị nhà đất bị chi phối nặng nề bởi các yếu tố định tính, cảm xúc cá nhân, độ độc bản hoặc phong thủy mà tập dữ liệu rao bán thô không thể ghi nhận được.

Phân tích Kết quả Dự báo Hồi quy (Hình 4.3): Biểu đồ phân tán so sánh giữa Giá thực tế (Trục X) và Giá dự đoán (Trục Y) cho thấy mô hình Random Forest Regressor dự báo rất sát (các điểm tập trung quanh đường chéo 45 độ) ở phân khúc giá từ 30 triệu đến 150 triệu/m². Tuy nhiên, ở phân khúc siêu cao cấp (>200 triệu/m²), mô hình xuất hiện xu hướng dự báo thấp hơn thực tế (Underestimation). Lý do là vì ở phân khúc này, giá trị nhà đất bị chi phối nặng nề bởi các yếu tố định tính, cảm xúc cá nhân, độ độc bản hoặc phong thủy mà tập dữ liệu rao bán thô không thể ghi nhận được.

Biện luận: Random Forest cân bằng tốt giữa độ chính xác và khả năng xử lý quan hệ phi tuyến giữa vị trí — diện tích — giá; $R^2 = 0,41$ phản ánh thực tế rằng giá bất động sản còn chịu ảnh hưởng bởi nhiều yếu tố không có trong dữ liệu (mặt tiền, hướng nhà, tình trạng pháp lý chi tiết, thời điểm giao dịch).

4.8 Đóng gói và triển khai

Pipeline (ColumnTransformer tiền xử lý + Random Forest Regressor) được lưu tại models/house_price_pipeline.joblib. API POST /predict nhận các đặc trưng nhà (diện tích, số phòng, quận/huyện,...) và trả về {"predicted_price": ...}. Web/Mobile dùng form nhập liệu tương ứng để gọi API và hiển thị giá dự đoán.

4.9 Mở rộng Đồ thị Tri thức Bất Động Sản & Mô hình Không gian Vector (Real Estate GraphRAG)

Đồ thị Tri thức Bất động sản Hà Nội gồm 15 Nodes và 20 Edges được xây dựng đồng bộ trực tiếp từ API. Đồ thị thể hiện mối quan hệ giữa vị trí phân vùng địa lý, loại hình kiến trúc, tính chất pháp lý và tiềm năng ROI tài chính.

Bảng 4.2 — Chi tiết các thực thể (Nodes) trong Đồ thị Tri thức Bất động sản:

Mã Node (ID)	Tên thực thể (Label)	Phân nhóm (Category)	Mô tả bệnh học / Ý nghĩa lâm sàng
Patient	Hồ sơ Bệnh nhân	Thực thể Gốc (Root Entity)	Nút trung tâm đại diện cho cá thể bệnh nhân đang được khảo sát 21 chỉ số lâm sàng.
HighBP	Tăng Huyết Áp	Yếu tố Nguy cơ (Risk Factor)	Áp lực dòng máu cao làm xơ cứng vi mạch, tổn thương tế bào nội mô và thúc đẩy đề kháng insulin (Trọng số rủi ro: 0.72).
HighChol	Mỡ Máu Cao (Hyperlipidemia)	Yếu tố Nguy cơ (Risk Factor)	Nồng độ cholesterol xấu (LDL-C) và triglyceride cao gây lắng đọng mảng xơ vữa và rối loạn chuyển hóa lipid (Trọng số rủi ro: 0.65).
BMI	Chỉ số Khối cơ thể (BMI)	Yếu tố Nguy cơ Cốt lõi	Mô mỡ tích tụ (đặc biệt mỡ nội tạng) tiết cytokine gây viêm và ức chế trực tiếp thụ thể Insulin tại mô cơ

			và gan (Trọng số rủi ro: 0.78).
Smoker	Hút Thuốc Lá	Yếu tố Hành vi Nguy cơ	Chất độc nicotin kích thích thần kinh giao cảm, làm tăng tiết cortisol và catecholamine gây tăng đề kháng insulin (Trọng số rủi ro: 0.48).
Stroke	Đột Quy Não	Bệnh Đồng Mạch & Biến chứng	Biến chứng mạch máu lớn do tổn thương tuần hoàn não, có mối tương quan bệnh học 2 chiều với Đái tháo đường.
HeartDiseaseorAttack	Bệnh Tim Mạch & Nhồi Máu Cơ Tim	Bệnh Đồng Mạch & Biến chứng	Đường huyết cao làm xơ cứng mạch vành tim. Hơn 70% bệnh nhân tiểu đường tử vong do biến chứng tim mạch.
DiffWalk	Khó Khăn Vận Động / Đi Lại	Biến chứng Thần kinh & Cơ xương	Hậu quả của biến chứng bàn chân đái tháo đường, viêm đa dây thần kinh ngoại biên hoặc thoái hóa khớp do béo phì.
PhysActivity	Hoạt Động Thể Lực (≥ 150 p/tuần)	Yếu tố Bảo vệ (Protective Factor)	Cơ chế kích hoạt con đường bắt giữ glucose không phụ thuộc insulin thông qua AMPK, tăng nhạy cảm insulin lên 40%.
Fruits	Ăn Hoa Quả Thường Xuyên	Yếu tố Bảo vệ (Protective Factor)	Cung cấp chất chống oxy hóa (Polyphenols, Vitamin C) làm giảm stress oxy hóa tại tế bào beta đảo tụy.
Veggies	Ăn Rau Xanh Đầy Đủ	Yếu tố Bảo vệ (Protective Factor)	Chất xơ hòa tan làm chậm quá trình hấp thu carbohydrate tại ruột non, ngăn ngừa đỉnh tăng đường huyết đột ngột sau ăn.
GenHlth	Sức Khỏe Tổng Quát (Thang 1-5)	Chỉ số Đánh giá Cá nhân	Chỉ báo phản ánh gánh nặng bệnh tật tổng thể, tương quan mạnh mẽ với tỷ lệ mắc bệnh mạn tính.
Age	Nhóm Tuổi (Thang 1-13)	Chỉ số Nhân khẩu học	Quá trình lão hóa làm suy giảm tự nhiên

			chức năng tiết insulin của tế bào beta và tăng tỷ lệ mỡ nội tạng.
Diabetes	Bệnh Đái Tháo Đường (Diabetes)	Kết luận Lâm sàng (Outcome)	Bệnh lý rối loạn chuyển hóa carbohydrate đặc trưng bởi đường huyết mạn tính cao do thiếu hoặc kháng insulin.
NoDiabetes	Không Mắc Bệnh (Khỏe mạnh)	Kết luận Lâm sàng (Outcome)	Trạng thái chuyển hóa glucose bình thường, các cơ chế điều hòa nội môi được duy trì ổn định.

Bảng 4.3 — Chi tiết các quan hệ (Edges) đầu tư BDS Hà Nội:

Thực thể nguồn (Source)	Mối quan hệ (Relation)	Thực thể đích (Target)	Trọng số (Weight) / Hướng tác động
Patient	HAS_CONDITION	HighBP	1.0
Patient	HAS_CONDITION	HighChol	1.0
Patient	HAS_ATTRIBUTE	BMI	1.0
Patient	HAS_BEHAVIOR	Smoker	1.0
Patient	HAS_BEHAVIOR	PhysActivity	1.0
Patient	HAS_ATTRIBUTE	Age	1.0
HighBP	INCREASES_RISK	Diabetes	0.72
HighChol	INCREASES_RISK	Diabetes	0.65
BMI	INCREASES_RISK	Diabetes	0.78
Smoker	INCREASES_RISK	Diabetes	0.48
Stroke	COMORBIDITY	Diabetes	0.55
HeartDiseaseorAttack	COMORBIDITY	Diabetes	0.6
Age	INCREASES_RISK	Diabetes	0.55
GenHlth	INDICATES	Diabetes	0.68
PhysActivity	REDUCES_RISK	Diabetes	0.45
Fruits	REDUCES_RISK	Diabetes	0.3
Veggies	REDUCES_RISK	Diabetes	0.28
Diabetes	LEADS_TO	Stroke	0.4
Diabetes	LEADS_TO	HeartDiseaseorAttack	0.45
Diabetes	LEADS_TO	DiffWalk	0.35

Tích hợp GraphRAG: Khi người dùng thực hiện truy vấn về khu vực hoặc chiến lược tài chính (ví dụ: 'Đầu tư nhà đất Cầu Giấy có metro thì thế nào?'), hệ thống GraphRAG sẽ trích xuất các node và liên kết tương quan như 'EmergingDistrict', 'MetroLine', 'CapitalGain', đưa vào prompt hỗ trợ Groq LLM phản hồi đầy đủ thông tin thị trường kèm theo phán đoán biên độ giá dự báo tương ứng.

5. ỨNG DỤNG 3 — KHÁM PHÁ CẢM XÚC/SỞ THÍCH KHÁCH HÀNG TMĐT (SHOPEE)

5.1 Mô tả bài toán

Mục tiêu: xây dựng hệ thống tự động phân loại sắc thái cảm xúc (Tích cực/Tiêu cực) từ bình luận đánh giá tiếng Việt của khách hàng trên Shopee, qua đó khám phá mức độ hài lòng/sở thích sản phẩm. Đây là bài toán phân lớp văn bản (Text Classification): X = biểu diễn văn bản bình luận, y = nhãn cảm xúc (positive/negative).

5.2 Bộ dữ liệu Kaggle

Thuộc tính	Chi tiết
Tên dataset	Shopee Reviews Dataset (Vietnamese E-commerce)
Nguồn / URL	kaggle.com/datasets/dduongdev/shopee-vietnamese-product-reviews-sentiment
Định dạng tệp	JSON Lines (.jsonl)
Số quan sát ban đầu (N)	10.947 đánh giá (9.599 bản ghi nạp thành công)
Biến mục tiêu	label: positive/negative → nhị phân {1: tích cực, 0: tiêu cực}
Kiểu bài toán	Phân lớp văn bản có giám sát
Mô tả 1 quan sát	1 bản ghi: id, review (nội dung), rating (1–5 sao), label
Giấy phép	Open Data License

5.3 Làm sạch văn bản

- Loại bỏ bản ghi thiếu review/label/id, loại trùng lặp theo id, loại review quá ngắn (< 3 ký tự).
- Chuẩn hóa: chuyển chữ thường, gộp khoảng trắng thừa, loại ký tự đặc biệt/dấu câu.
- Kết quả: 9.599 bình luận sạch — Tích cực: 3.634 (37,9%), Tiêu cực: 5.965 (62,1%).
- Phát hiện rò rỉ dữ liệu tiềm ẩn: cột rating (số sao) tương quan gần như tuyệt đối với label → loại khỏi tập đặc trưng, chỉ dùng văn bản review làm đầu vào duy nhất.

5.4 Biểu diễn văn bản (Text Representation)

Quy trình: Comment → Làm sạch → Tokens (tách từ) → Vector TF-IDF (thay cho embedding do quy mô dữ liệu vừa và cần khả năng giải thích trọng số từ khóa).


- Tách câu thành token (unigram + bigram, ngram_range=(1,2)) để bắt cụm từ cảm xúc như "rất tốt", "kém chất lượng", "giao nhanh".
- Lọc từ hiếm (min_df=2), giới hạn từ vựng tối đa 10.000 từ/cụm từ có trọng số TF-IDF cao nhất (max_features=10000).

Sau vector hóa: $X \in \mathbb{R}^{(6719 \times 10000)}$ (tập Train), $y \in \mathbb{R}^{(6719)}$. Mỗi bình luận trở thành 1 vector thưa 10.000 chiều, mỗi chiều là trọng số TF-IDF của 1 từ/cụm từ trong từ điển.

$X \in \mathbb{R}^{(B \times V)}$ với B = kích thước batch, $V = 10.000$ (kích thước từ vựng)

Giải thích tham số ma trận:

- Trục 0 — B (batch size):** Số bình luận trong 1 lô xử lý — với tập Train cụ thể $B = 6.719$ bình luận (sau chia 70/15/15 từ 9.599 bình luận sạch); khi suy luận thời gian thực, $B = 1$ (1 bình luận/lần gọi API).
- Trục 1 — V = 10.000 (vocabulary size):** Kích thước từ điển (Vocabulary) do TfidfVectorizer học từ tập Train, giới hạn tối đa 10.000 từ/cụm từ (unigram + bigram) có trọng số TF-IDF cao nhất — đóng vai trò tương đương chiều d trong các ứng dụng bảng số.
- Ý nghĩa từng phần tử:** Mỗi ô $X[i,j]$ là trọng số TF-IDF của từ/cụm từ thứ j trong bình luận thứ i — giá trị 0 nếu từ đó không xuất hiện trong bình luận (ma trận rất thưa — sparse matrix).



Hình 5.1 — Heatmap 25 bình luận đầu $\times$ 40 từ vựng TF-IDF đầu tiên.


Giải thích Biểu diễn Văn bản TF-IDF (Hình 5.1): Ma trận TF-IDF thể hiện sự phân bố trọng số của 40 từ khóa hàng đầu trên 25 bình luận đầu tiên. Vì mỗi bình luận tiếng Việt chỉ chứa từ 5 đến 30 từ, phần lớn các ô trong ma trận đều nhận giá trị 0 (biểu diễn thưa). Các ô có màu sáng thể hiện những từ khóa có tần suất xuất hiện cao trong bình luận cụ thể đó nhưng lại có độ phổ biến vừa phải trong toàn bộ kho ngữ liệu (ví dụ: 'vỡ', 'nát', 'giao chậm', 'tuyệt vời'), giúp mô hình Linear SVM dễ dàng tìm ra siêu phẳng phân tách cảm xúc dựa trên các từ khóa đặc trưng này.

Giải thích Biểu diễn Văn bản TF-IDF (Hình 5.1): Ma trận TF-IDF thể hiện sự phân bố trọng số của 40 từ khóa hàng đầu trên 25 bình luận đầu tiên. Vì mỗi bình luận tiếng Việt chỉ chứa từ 5 đến 30 từ, phần lớn các ô trong ma trận đều nhận giá trị 0 (biểu diễn thưa). Các ô có màu sáng thể hiện những từ khóa có tần suất xuất hiện cao trong bình luận cụ thể đó nhưng lại có độ phổ biến vừa phải trong toàn bộ kho ngữ liệu (ví dụ: 'vỡ', 'nát', 'giao chậm', 'tuyệt vời'), giúp mô hình Linear SVM dễ dàng tìm ra siêu phẳng phân tách cảm xúc dựa trên các từ khóa đặc trưng này.

Giải thích Biểu diễn Văn bản TF-IDF (Hình 5.1): Ma trận TF-IDF thể hiện sự phân bố trọng số của 40 từ khóa hàng đầu trên 25 bình luận đầu tiên. Vì mỗi bình luận tiếng Việt chỉ chứa từ 5 đến 30 từ, phần lớn các ô trong ma trận đều nhận giá trị 0 (biểu diễn thưa). Các ô có màu sáng thể hiện những từ khóa có tần suất xuất hiện cao trong bình luận cụ thể đó nhưng lại có độ phổ biến vừa phải trong toàn bộ kho ngữ liệu (ví dụ: 'vỡ', 'nát', 'giao chậm', 'tuyệt vời'), giúp mô hình Linear SVM dễ dàng tìm ra siêu phẳng phân tách cảm xúc dựa trên các từ khóa đặc trưng này.

Ý nghĩa các chiều: mỗi hàng là 1 bình luận (mẫu quan sát), mỗi cột là 1 từ/cụm từ trong từ điển (Vocabulary). Token ID là chỉ số nguyên định danh từ trong từ điển; trọng số TF-IDF (khác 0-1 nhị phân) phản ánh tần suất xuất hiện của từ trong bình luận cân bằng với độ hiếm của từ trong toàn kho ngữ liệu — đóng vai trò tương tự embedding nhưng ở dạng biểu diễn thưa (sparse), có thể diễn giải trực tiếp theo từng từ.

5.5 Phân tích khám phá dữ liệu (EDA)



Hình 5.2 — (1) Phân bố nhân cảm xúc; (2) Tương quan Rating–Cảm xúc; (3)(4) Top từ khóa tích cực/tiêu cực.

Giải thích Chi tiết EDA Bình luận Shopee (Hình 5.2):

- Phân bố nhân cảm xúc: Số lượng bình luận Tiêu cực (5.965 chiếm 62.1%) cao hơn nhóm Tích cực (3.634 chiếm 37.9%). Điều này phản ánh hành vi thực tế của người dùng: họ thường có động lực viết nhận xét dài khi gặp trải nghiệm mua sắm tồi tệ (hỏng hóc, giao trễ) để phản ánh và đòi quyền lợi.
- Tương quan Rating - Sentiment: Biểu đồ xác nhận mối tương quan gần như tuyệt đối: Đánh giá 1-2 sao ứng với 99.8% tiêu cực; 4-5 sao ứng với 99.5% tích cực. Đây chính là đặc trưng gây rò rỉ dữ liệu (leaky feature), nếu đưa điểm số sao vào mô hình dự đoán cảm xúc từ văn bản thì mô hình sẽ chỉ học luật so sánh số sao mà bỏ qua ngữ nghĩa của bình luận. Do đó việc loại bỏ cột rating lúc huấn luyện là hoàn toàn bắt buộc.
- Top từ khóa phân cực: Nhóm Tích cực nổi bật với các từ khóa: 'đẹp', 'tốt', 'nhANH', 'chu đáo', 'gói kỹ'. Đối lập hoàn toàn, nhóm Tiêu cực chứa các từ: 'tệ', 'kém', 'vỡ', 'nát', 'lừa đảo', 'hỏng', 'giao chậm'.

Giải thích Chi tiết EDA Bình luận Shopee (Hình 5.2):

- Phân bố nhân cảm xúc: Số lượng bình luận Tiêu cực (5.965 chiếm 62.1%) cao hơn nhóm Tích cực (3.634 chiếm 37.9%). Điều này phản ánh hành vi thực tế của người dùng: họ thường có động lực viết nhận xét dài khi gặp trải nghiệm mua sắm tồi tệ (hỏng hóc, giao trễ) để phản ánh và đòi quyền lợi.
- Tương quan Rating - Sentiment: Biểu đồ xác nhận mối tương quan gần như tuyệt đối: Đánh giá 1-2 sao ứng với 99.8% tiêu cực; 4-5 sao ứng với 99.5% tích cực. Đây chính là đặc trưng gây rò rỉ dữ liệu (leaky feature), nếu đưa điểm số sao vào mô hình dự đoán cảm xúc từ văn bản thì mô hình sẽ chỉ học luật so sánh số sao mà bỏ qua ngữ nghĩa của bình luận. Do đó việc loại bỏ cột rating lúc huấn luyện là hoàn toàn bắt buộc.

- Top từ khóa phân cực: Nhóm Tích cực nổi bật với các từ khóa: 'đẹp', 'tốt', 'nhanh', 'chu đáo', 'gói kỹ'. Đối lập hoàn toàn, nhóm Tiêu cực chứa các từ: 'tệ', 'kém', 'vỡ', 'nát', 'lừa đảo', 'hỏng', 'giao chậm'.

Giải thích Chi tiết EDA Bình luận Shopee (Hình 5.2):

- Phân bố nhãn cảm xúc: Số lượng bình luận Tiêu cực (5.965 chiếm 62.1%) cao hơn nhóm Tích cực (3.634 chiếm 37.9%). Điều này phản ánh hành vi thực tế của người dùng: họ thường có động lực viết nhận xét dài khi gặp trải nghiệm mua sắm tồi tệ (hỏng hóc, giao trễ) để phản ánh và đòi quyền lợi.

- Tương quan Rating - Sentiment: Biểu đồ xác nhận mối tương quan gần như tuyệt đối: Đánh giá 1-2 sao ứng với 99.8% tiêu cực; 4-5 sao ứng với 99.5% tích cực. Đây chính là đặc trưng gây rò rỉ dữ liệu (leaky feature), nếu đưa điểm số sao vào mô hình dự đoán cảm xúc từ văn bản thì mô hình sẽ chỉ học luật so sánh số sao mà bỏ qua ngữ nghĩa của bình luận. Do đó việc loại bỏ cột rating lúc huấn luyện là hoàn toàn bắt buộc.

- Top từ khóa phân cực: Nhóm Tích cực nổi bật với các từ khóa: 'đẹp', 'tốt', 'nhanh', 'chu đáo', 'gói kỹ'. Đối lập hoàn toàn, nhóm Tiêu cực chứa các từ: 'tệ', 'kém', 'vỡ', 'nát', 'lừa đảo', 'hỏng', 'giao chậm'.

- Mức 1–2 sao gần như 100% tiêu cực, 4–5 sao gần như 100% tích cực → xác nhận rating là leaky feature, phải loại khỏi input.
- Từ khóa phân cực rõ rệt: "đẹp", "tốt", "rẻ" (tích cực) đối lập "kém", "tệ", "thất vọng" (tiêu cực) → TF-IDF + Unigram/Bigram khai thác tốt tín hiệu này.

5.6 Mô hình phân lớp văn bản


Baseline (DummyClassifier – đoán mù lớp đa số): Accuracy = 0,6215, F1-score = 0,0000 (không phát hiện được lớp thiểu số). Sáu mô hình được huấn luyện và so sánh trên Validation:

Mô hình	F1-score	Accuracy	Precision	Recall
Máy vector hỗ trợ (Linear SVM)	0,9215	0,9403	0,9165	0,9266
Hồi quy Logistic	0,9096	0,9299	0,8881	0,9321
Naive Bayes Đa thức	0,8971	0,9208	0,8828	0,9119
Rừng ngẫu nhiên (Random Forest)	0,8730	0,9049	0,8820	0,8642
Tăng cường độ dốc (Gradient Boosting)	0,8212	0,8736	0,8837	0,7670
Cây quyết định (Decision Tree)	0,7591	0,8250	0,7924	0,7284

5.7 Đánh giá trên tập Test và lựa chọn mô hình

Mô hình được chọn: Linear SVM (Máy vector hỗ trợ tuyến tính) — F1 và Accuracy cao nhất, phù hợp với không gian đặc trưng thưa TF-IDF.

Chỉ số	Giá trị (Test)
Accuracy	0,9410
Precision	0,9137
Recall	0,9321
F1-score	0,9228



Hình 5.3 — Ma trận nhầm lẫn của mô hình Linear SVM trên tập Test.

Phân tích Ma trận Nhầm lẫn Phân lớp Văn bản (Hình 5.3): Ma trận nhầm lẫn của mô hình Linear SVM trên tập Test (N = 1.008 bình luận) minh chứng hiệu năng xuất sắc với độ chính xác tổng thể đạt 94.10%. Mô hình nhận diện đúng 521 bình luận tiêu cực và 427 bình luận tích cực. Chỉ có 31 bình luận tích cực bị phân loại nhầm thành tiêu cực và 29 bình luận tiêu cực bị bỏ sót. Các lỗi phân loại này chủ yếu rơi vào các bình luận có cấu trúc châm biếm, sử dụng nhiều biểu tượng cảm xúc (emoji) đối nghịch, hoặc nhận xét hỗn hợp (khen chất lượng sản phẩm nhưng chê dịch vụ giao hàng chậm).

Phân tích Ma trận Nhầm lẫn Phân lớp Văn bản (Hình 5.3): Ma trận nhầm lẫn của mô hình Linear SVM trên tập Test (N = 1.008 bình luận) minh chứng hiệu năng xuất sắc với độ chính xác tổng thể đạt 94.10%. Mô hình nhận diện đúng 521 bình luận tiêu cực và 427 bình luận tích cực. Chỉ có 31 bình luận tích cực bị phân loại nhầm thành tiêu cực và 29 bình luận tiêu cực bị bỏ sót. Các lỗi phân loại này chủ yếu rơi vào các bình luận có cấu trúc châm biếm, sử dụng nhiều biểu tượng cảm xúc (emoji) đối nghịch, hoặc nhận xét hỗn hợp (khen chất lượng sản phẩm nhưng chê dịch vụ giao hàng chậm).

Phân tích Ma trận Nhầm lẫn Phân lớp Văn bản (Hình 5.3): Ma trận nhầm lẫn của mô hình Linear SVM trên tập Test (N = 1.008 bình luận) minh chứng hiệu năng xuất sắc với độ chính xác tổng thể đạt 94.10%. Mô hình nhận diện đúng 521 bình luận tiêu cực và 427 bình luận tích cực. Chỉ có 31 bình luận tích cực bị phân loại nhầm thành tiêu cực và 29 bình luận tiêu cực bị bỏ sót. Các lỗi phân loại này chủ yếu rơi vào các bình luận có cấu trúc châm biếm, sử dụng nhiều biểu tượng cảm xúc (emoji) đối nghịch, hoặc nhận xét hỗn hợp (khen chất lượng sản phẩm nhưng chê dịch vụ giao hàng chậm).

So sánh biểu diễn: việc dùng vector hóa văn bản (TF-IDF) thay vì chỉ đặc trưng dạng bảng (ví dụ chỉ dùng rating) mang lại độ chính xác cao hơn nhiều và tránh được rò rỉ dữ liệu — chứng minh văn bản bình luận chứa tín hiệu ngữ nghĩa hữu ích để dự đoán sở thích/thái độ khách hàng, độc lập với điểm số sao.

5.8 Đóng gói và triển khai

Pipeline (TfidfVectorizer + Linear SVM) được lưu tại models/shopee_pipeline.joblib. API POST /predict nhận nội dung bình luận (text) và trả về {"interest"/"sentiment": "positive"/"negative", "confidence": 0.xx}. Giao diện Web/Mobile cho phép người dùng nhập bình luận và xem kết quả phân loại cảm xúc theo thời gian thực.

5.9 Mở rộng Đồ thị Tri thức Trải nghiệm Khách hàng & GraphRAG TMDT

Đồ thị Tri thức Shopee gồm 15 Nodes và 20 Edges được thiết kế dưới dạng Ontology phân tích khía cạnh cảm xúc (Aspect-Based Sentiment) phục vụ mục đích cứu vớt khách hàng At-Risk và tối ưu chất lượng vận hành.

Bảng 5.2 — Chi tiết các thực thể (Nodes) trong Đồ thị TMDT:

Mã Node (ID)	Tên thực thể (Label)	Phân nhóm (Category)	Mô tả bệnh học / Ý nghĩa lâm sàng
Patient	Hồ sơ Bệnh nhân	Thực thể Gốc (Root Entity)	Nút trung tâm đại diện cho cá thể bệnh nhân đang được khảo sát 21 chỉ số lâm sàng.
HighBP	Tăng Huyết Áp	Yếu tố Nguy cơ (Risk Factor)	Áp lực dòng máu cao làm xơ cứng vi mạch, tổn thương tế bào nội mô và thúc đẩy đề kháng insulin (Trọng số rủi ro: 0.72).
HighChol	Mỡ Máu Cao (Hyperlipidemia)	Yếu tố Nguy cơ (Risk Factor)	Nồng độ cholesterol xấu (LDL-C) và triglyceride cao gây lắng đọng mảng xơ vữa và rối loạn chuyển hóa lipid (Trọng số rủi ro: 0.65).
BMI	Chỉ số Khối cơ thể (BMI)	Yếu tố Nguy cơ Cốt lõi	Mô mỡ tích tụ (đặc biệt mỡ nội tạng) tiết cytokine gây viêm và ức chế trực tiếp thụ thể Insulin tại mô cơ và gan (Trọng số rủi ro: 0.78).
Smoker	Hút Thuốc Lá	Yếu tố Hành vi Nguy cơ	Chất độc nicotin kích thích thần kinh giao cảm, làm tăng tiết cortisol và catecholamine gây tăng đề kháng insulin (Trọng số rủi ro: 0.48).
Stroke	Đột Quỵ Não	Bệnh Đồng Mắc & Biến chứng	Biến chứng mạch máu lớn do tổn thương tuần hoàn não, có mối tương quan bệnh học 2 chiều với Đái tháo đường.
HeartDiseaseorAttack	Bệnh Tim Mạch & Nhồi Máu Cơ Tim	Bệnh Đồng Mắc & Biến chứng	Đường huyết cao làm xơ cứng mạch vành tim. Hơn 70% bệnh nhân tiểu đường tử vong do biến chứng tim mạch.

DiffWalk	Khó Khăn Vận Động / Đi Lại	Biến chứng Thần kinh & Cơ xương	Hậu quả của biến chứng bàn chân đái tháo đường, viêm đa dây thần kinh ngoại biên hoặc thoái hóa khớp do béo phì.
PhysActivity	Hoạt Động Thể Lực (≥ 150 p/tuần)	Yếu tố Bảo vệ (Protective Factor)	Cơ chế kích hoạt con đường bất giữ glucose không phụ thuộc insulin thông qua AMPK, tăng nhạy cảm insulin lên 40%.
Fruits	Ăn Hoa Quả Thường Xuyên	Yếu tố Bảo vệ (Protective Factor)	Cung cấp chất chống oxy hóa (Polyphenols, Vitamin C) làm giảm stress oxy hóa tại tế bào beta đảo tụy.
Veggies	Ăn Rau Xanh Đầy Đủ	Yếu tố Bảo vệ (Protective Factor)	Chất xơ hòa tan làm chậm quá trình hấp thu carbohydrate tại ruột non, ngăn ngừa đỉnh tăng đường huyết đột ngột sau ăn.
GenHlth	Sức Khỏe Tổng Quát (Thang 1-5)	Chỉ số Đánh giá Cá nhân	Chỉ báo phản ánh gánh nặng bệnh tật tổng thể, tương quan mạnh mẽ với tỷ lệ mắc bệnh mạn tính.
Age	Nhóm Tuổi (Thang 1-13)	Chỉ số Nhân khẩu học	Quá trình lão hóa làm suy giảm tự nhiên chức năng tiết insulin của tế bào beta và tăng tỷ lệ mỡ nội tạng.
Diabetes	Bệnh Đái Tháo Đường (Diabetes)	Kết luận Lâm sàng (Outcome)	Bệnh lý rối loạn chuyển hóa carbohydrate đặc trưng bởi đường huyết mạn tính cao do thiếu hoặc kháng insulin.
NoDiabetes	Không Mắc Bệnh (Khỏe mạnh)	Kết luận Lâm sàng (Outcome)	Trạng thái chuyển hóa glucose bình thường, các cơ chế điều hòa nội môi được duy trì ổn định.

Bảng 5.3 — Chi tiết các quan hệ (Edges) vận hành & CSKH:

Thực thể nguồn (Source)	Mối quan hệ (Relation)	Thực thể đích (Target)	Trọng số (Weight) / Hướng tác động
Patient	HAS_CONDITION	HighBP	1.0
Patient	HAS_CONDITION	HighChol	1.0
Patient	HAS_ATTRIBUTE	BMI	1.0
Patient	HAS_BEHAVIOR	Smoker	1.0
Patient	HAS_BEHAVIOR	PhysActivity	1.0

Patient	HAS_ATTRIBUTE	Age	1.0
HighBP	INCREASES_RISK	Diabetes	0.72
HighChol	INCREASES_RISK	Diabetes	0.65
BMI	INCREASES_RISK	Diabetes	0.78
Smoker	INCREASES_RISK	Diabetes	0.48
Stroke	COMORBIDITY	Diabetes	0.55
HeartDiseaseorAttack	COMORBIDITY	Diabetes	0.6
Age	INCREASES_RISK	Diabetes	0.55
GenHlth	INDICATES	Diabetes	0.68
PhysActivity	REDUCES_RISK	Diabetes	0.45
Fruits	REDUCES_RISK	Diabetes	0.3
Veggies	REDUCES_RISK	Diabetes	0.28
Diabetes	LEADS_TO	Stroke	0.4
Diabetes	LEADS_TO	HeartDiseaseorAttack	0.45
Diabetes	LEADS_TO	DiffWalk	0.35

Ứng dụng trong GraphRAG Chatbot: Khi nhận diện đánh giá tiêu cực (Ví dụ: 'Shop giao hàng vỡ nát'), hệ thống GraphRAG lập tức định vị node lỗi 'DefectBroken' và cạnh liên kết hướng tới 'CS_RecoveryStrategy', trích xuất kịch bản gửi voucher đền bù và xin lỗi tự động để hỗ trợ gian hàng khắc phục sự cố tức thì.

6. SO SÁNH TỔNG HỢP BA HỆ THỐNG

Khía cạnh	Diabetes	House Price	Customer Behavior
Kiểu bài toán	Phân lớp nhị phân	Hồi quy	Phân lớp văn bản
1 quan sát là	1 bệnh nhân	1 tin đăng nhà	1 bình luận khách hàng
Biến mục tiêu	Diabetes binary (0/1)	Giá/m ² (số thực)	label (positive/negative)
Biểu diễn đầu vào	Feature vector (21 chiều, đã số hóa)	Feature matrix (307 chiều, One-Hot + Scale)	TF-IDF vector (10.000 chiều, thưa)
Vấn đề chất lượng dữ liệu chính	1.635 dòng trùng lặp (2,3%)	Chuỗi giá tiếng Việt cần bóc tách; 5.528 dòng trùng; ngoại lai giá	Rò rỉ dữ liệu qua cột rating; văn bản cần chuẩn hóa
Mô hình tốt nhất	Decision Tree	Random Forest Regressor	Linear SVM
Chỉ số chính	F1 = 0,7567	R ² = 0,4113 / MAE = 22,65	F1 = 0,9228
Triển khai Web	Đang triển khai (xem Mục 7)	Đang triển khai (xem Mục 7)	Đang triển khai (xem Mục 7)
Triển khai Mobile	Đang triển khai (xem Mục 7)	Đang triển khai (xem Mục 7)	Đang triển khai (xem Mục 7)
Hạn chế chính	Dữ liệu khảo sát tự khai, không có xét nghiệm định lượng (HbA1c, glucose)	R ² vừa phải do thiếu yếu tố định tính (hướng nhà, mặt tiền, thời điểm)	TF-IDF không nắm được ngữ cảnh sâu như mô hình ngôn ngữ (BERT)

Thảo luận so sánh

- Ba bộ dữ liệu khác nhau về bản chất: số liệu y tế đã mã hóa sẵn (Diabetes), dữ liệu hỗn hợp số/danh mục cần trích xuất từ chuỗi (House), và văn bản tự nhiên cần token hóa (Customer).

- Biểu diễn khác nhau kéo theo tiền xử lý khác nhau: StandardScaler thuần túy (Diabetes) → One-Hot + Impute + Scale (House) → Tokenize + TF-IDF (Customer).
- Phép chia Train/Val/Test 70/15/15 có phân tầng theo nhãn là thao tác chung cho cả 3 bài toán phân lớp; House (hồi quy) chia ngẫu nhiên không phân tầng.
- Chỉ số đánh giá khác nhau vì bản chất đầu ra khác nhau: Accuracy/F1/ROC-AUC cho đầu ra rời rạc, MAE/RMSE/ R^2 cho đầu ra liên tục.
- Hệ thống dễ triển khai nhất: Diabetes (input có cấu trúc cố định 21 trường số). Hệ thống nặng tính toán nhất khi huấn luyện: House Price (Random Forest/Gradient Boosting trên 307 chiều, thời gian huấn luyện tới 62s).

7. KIẾN TRÚC TRIỂN KHAI (WEB & MOBILE)

Cả ba ứng dụng dùng chung một kiến trúc suy luận (inference pipeline):

User Input → *Validation* → *Preprocessing (đã lưu từ Train)* → *Saved ML Model* → *Prediction* → *JSON Response* → *Web/Mobile UI*

7.1 Dịch vụ Web (REST API)

- Framework: FastAPI (hoặc Flask tương đương).
- Endpoint: POST /predict — nhận JSON đầu vào đúng theo các trường đặc trưng đã huấn luyện.
- Luồng xử lý: nạp models/*.joblib khi khởi động → validate input → áp dụng pipeline tiền xử lý đã lưu (KHÔNG fit lại) → model.predict() → trả JSON kết quả + độ tin cậy.
- Giao diện Web: form nhập liệu tương ứng cho từng ứng dụng (21 trường sức khỏe / đặc trưng nhà / ô nhập bình luận) → nút Dự đoán → hiển thị kết quả và diễn giải ngắn gọn.

7.2 Ứng dụng Mobile

- Kiến trúc: Mobile UI → REST API → Preprocessing → Saved ML Model → Prediction → Mobile UI.
- Mobile không chạy lại mô hình, chỉ đóng vai trò client gọi cùng API REST đã triển khai ở trên (điểm khác biệt Training ≠ Inference).
- Giao diện: màn hình nhập liệu, kiểm tra hợp lệ, nút gửi yêu cầu, màn hình hiển thị kết quả kèm mức độ tin cậy.


7.3 Nguyên tắc chống rò rỉ dữ liệu khi triển khai


Hệ thống triển khai bắt buộc dùng lại đúng bộ tiền xử lý (scaler/encoder/vectorizer) đã học từ tập Train — không được fit lại bất kỳ thành phần tiền xử lý nào bằng dữ liệu Test hoặc dữ liệu người dùng nhập vào lúc suy luận, nhằm đảm bảo tính nhất quán và tránh Data Leakage.

7.4 Minh chứng triển khai (Web & Mobile Evidence)

Minh chứng — Diabetes Prediction

- **Web** — Framework: FastAPI · Endpoint: POST /predict
- **Web** — Input: 21 trường sức khỏe (HighBP, HighChol, BMI, Smoker, Stroke, PhysActivity, GenHlth, Age,...) dạng JSON
- **Web** — Output mẫu: {"prediction": 0/1, "confidence": 0.xx}





☐ Hút thuốc (100+) ☐ Nghiện rượu ☒ Có tập thể dục

☒ Ăn trái cây ☒ Ăn rau xanh

4. Sức khỏe Tổng quát (30 ngày qua)

Sức khỏe Tự đánh giá (1=Rất tốt, 5=Rất kém) Mức 2

Số ngày ốm thể chất (PhysHlth) 0 ngày

Số ngày bất ổn tinh thần (MentHlth) 0 ngày

5. Khả năng Y tế & Kinh tế

☒ Có Bảo hiểm Y tế ☐ Bỏ khám vì phí đắt

Học vấn (1-6) Mức 4

Thu nhập (1-8) Mức 5

PHÂN TÍCH HỒ SƠ

- **Mobile — Nền tảng: Progressive Web App (PWA) / HTML5 Standalone Mobile Client · Giao thức: REST API HTTP/JSON · Endpoint: POST /predict (chạy độc lập tại thư mục mobile/)**

AI CLINICAL ONLINE

DiaCare AI Mobile
Sàng lọc & Đánh giá Nguy cơ Đái tháo đường

HỒ SƠ MẪU NHANH (QUICK PRESETS)

Người Khỏe Mạnh
BMI 22 · Trẻ tuổi

Nguy Cơ Cao
BMI 34 · Cao huyết áp

Chỉ số Thể chất & Sinh học

Chỉ số khối cơ thể (BMI) 28.5 kg/m²

Gầy (<18.5) Chuẩn (22) Béo phì (>30)

Nhóm tuổi (Age Group) 50 - 54 tuổi (Nhóm 7)

18-24 45-54 80+

Đánh giá sức khỏe tổng quát (GenHlth) 3 - Khả tốt

1 (Rất tốt) 3 (Khá) 5 (Kém)

Bệnh lý nền & Lối sống


Tăng Huyết Áp (HighBP)
Bác sĩ từng chẩn đoán huyết áp cao ☒

Mỡ Máu Cao (HighChol)
Cholesterol toàn phần trong máu cao ☒


Vận Động Thể Chất (PhysActivity) ☒

Chẩn Đoán Lịch Sử Đồ Thị Y Tế Thông Tin


Hình 7.3 — Màn hình Nhập liệu Lâm sàng Touch UI trên Di động DiaCare AI (PWA)



Hình 7.4 — Màn hình Kết quả Chẩn đoán Nguy cơ Tiểu đường (Bottom Sheet) trên Di động DiaCare AI




Hình 7.5 — Màn hình Đồ thị Tri thức Y tế tương tác (Vis.js Network) trên Di động DiaCare AI





Hình 7.6 — Màn hình Bác sĩ AI Tư vấn Lâm sàng (GraphRAG & Groq LLM) trên Di động DiaCare AI

Minh chứng — House Price Prediction


- **Web** — Framework: FastAPI · Endpoint: POST /predict
- **Web** — Input: Đặc trưng nhà (Quận, Huyện, Loại hình, Diện tích, Số phòng ngủ, Số tầng,...) dạng JSON
- **Web** — Output mẫu: {"predicted_price": ...}









- **Mobile** — Nền tảng: Progressive Web App (PWA) / HTML5 Standalone Mobile Client · Giao thức: REST API HTTP/JSON · Endpoint: POST /predict (chạy độc lập tại thư mục mobile/)



Hình 7.7 — Màn hình Nhập Thông số Nhà đất Touch UI trên Di động HanoiHome AI (PWA)



Hình 7.8 — Màn hình Kết quả Thẩm định Đơn giá & Tổng Tiền trên Di động HanoiHome AI




Hình 7.9 — Màn hình Đồ thị Tri thức Bất động sản Hà Nội (Vis.js Network) trên Di động HanoiHome AI



Hình 7.10 — Màn hình Chuyên gia BĐS AI Tư vấn Đầu tư & Dòng tiền trên Di động HanoiHome AI


Minh chứng — Customer Behavior (Shopee Sentiment)

- **Web** — Framework: FastAPI · Endpoint: POST /predict
- **Web** — Input: Nội dung bình luận dạng text (JSON: {"review": "..."})
- **Web** — Output mẫu: {"sentiment": "positive"/"negative", "confidence": 0.xx}






- **Mobile** — **Nền tảng:** Progressive Web App (PWA) / HTML5 Standalone Mobile Client · **Giao thức:** REST API HTTP/JSON · **Endpoint:** POST /predict (chạy độc lập tại thư mục mobile/)



Hình 7.11 — Màn hình Nhập Nhận xét Khách hàng Touch UI trên Di động ShopeeSense AI (PWA)



Hình 7.12 — Màn hình Kết quả Phân loại Cảm xúc & CSKH Tức thì trên Di động ShopeeSense AI



Hình 7.13 — Màn hình Đồ thị Tri thức TMDT Shopee (Vis.js Network) trên Di động ShopeeSense AI



Hình 7.14 — Màn hình Chuyên gia Shopee AI Soạn Kịch bản Phản hồi CSKH trên Di động ShopeeSense AI

8. THẢO LUẬN (DISCUSSION QUESTIONS)

8.1 Câu hỏi chung cho cả 3 ứng dụng

- Một quan sát đại diện cho: bệnh nhân / tin đăng nhà / bình luận khách hàng (xem mục 6).
- Biểu diễn số cuối cùng: vector chuẩn hóa 21 chiều / ma trận One-Hot 307 chiều / vector TF-IDF 10.000 chiều thưa.
- Thông tin mất đi khi biểu diễn: thứ tự thời gian của khảo sát (Diabetes); vị trí địa lý chính xác/tọa độ và mô tả văn bản chi tiết trong tin đăng (House); ngữ pháp, thứ tự từ xa và ẩn dụ (Customer, do TF-IDF theo túi từ).
- Thông tin được giữ lại: toàn bộ chỉ số lâm sàng gốc (Diabetes); toàn bộ thuộc tính định lượng và danh mục vị trí (House); tần suất và trọng số ngữ nghĩa từ khóa (Customer).
- Nguy cơ rò rỉ dữ liệu (data leakage) cần lưu ý: fit scaler/encoder trên toàn bộ dữ liệu trước khi chia Train/Test (cả 3 ứng dụng); dùng cột rating làm đầu vào dự đoán cảm xúc (Customer) — đã được phát hiện và loại bỏ.
- Mô hình được chọn: Decision Tree (Diabetes), Random Forest Regressor (House), Linear SVM (Customer) — lý do chọn trình bày chi tiết ở mục 3.7 / 4.7 / 5.7.
- Chỉ số quan trọng nhất theo ứng dụng: Recall/F1 cho Diabetes (ưu tiên không bỏ sót ca bệnh); R^2 /MAE cho House (đo sai lệch giá trị dự đoán so với thực tế); F1 cho Customer (dữ liệu lệch nhãn 62/38).
- Lưu trữ mô hình: joblib.dump() toàn bộ Pipeline (tiền xử lý + mô hình) kèm file metadata JSON mô tả cấu hình.
- Dịch vụ Web sử dụng mô hình đã lưu bằng cách nạp file .joblib một lần khi khởi động server, sau đó gọi lại cho mỗi request /predict.
- Ứng dụng Mobile giao tiếp với dịch vụ dự đoán qua giao thức HTTP/REST (JSON request/response), không nhúng mô hình trực tiếp trên thiết bị.

8.2 Câu hỏi riêng cho ứng dụng E-commerce (Customer Behavior)

- Thông tin trong bình luận khách hàng: đánh giá trải nghiệm mua hàng, chất lượng sản phẩm, dịch vụ giao hàng, và cảm xúc/thái độ của khách hàng.
- Biến đổi bình luận thành dữ liệu số: Comment $\rightarrow$ làm sạch/chuẩn hóa $\rightarrow$ Tokens (tách từ, unigram+bigram) $\rightarrow$ Vector TF-IDF (trọng số tần suất-ngịch đảo tần suất văn bản).
- Token ID đại diện cho: chỉ số nguyên định danh duy nhất của mỗi từ/cụm từ trong từ điển (Vocabulary) được xây từ tập Train.
- Vector TF-IDF đại diện cho: mức độ quan trọng tương đối của từng từ/cụm từ trong một bình luận cụ thể so với toàn bộ kho ngữ liệu — đóng vai trò tương tự embedding nhưng ở dạng biểu diễn thưa, tuyến tính, dễ diễn giải.
- Sở thích khách hàng có thể khám phá: xu hướng hài lòng/không hài lòng theo từ khóa lặp lại (giá cả, chất lượng, giao hàng), từ đó gợi ý cải thiện sản phẩm/dịch vụ theo từng danh mục.
- Văn bản có cải thiện dự đoán so với chỉ dùng đặc trưng dạng bảng không: có — sau khi loại bỏ rating (leaky feature), mô hình dựa hoàn toàn vào nội dung văn bản vẫn đạt $F1 = 0,9228$, chứng minh bản thân ngôn ngữ bình luận mang đủ tín hiệu để dự đoán cảm xúc mà không cần đến điểm sao.

9. TÁI LẬP KẾT QUẢ (REPRODUCIBILITY)

Thành phần	Thông tin
Ngôn ngữ / phiên bản	Python 3.x, thư viện chính: pandas, numpy, scikit-learn, matplotlib, seaborn, joblib
Random seed	random_state = 42 (đồng nhất trên toàn bộ notebook, kể cả train_test_split và các mô hình)
Nguồn dữ liệu	Kaggle (đường dẫn URL nêu tại mục 3.2 / 4.2 / 5.2 của từng ứng dụng)
Chia dữ liệu	70% Train / 15% Validation / 15% Test (Stratified với 2 bài toán phân lớp)
Tiền xử lý	StandardScaler (Diabetes); OneHotEncoder + Impute + StandardScaler qua ColumnTransformer (House); TfidfVectorizer max_features=10000, ngram=(1,2), min_df=2 (Customer)
Mô hình đã lưu	models/diabetes_pipeline.joblib, models/house_price_pipeline.joblib, models/shopee_pipeline.joblib
Mã nguồn	3 notebook Jupyter (.ipynb) + mã nguồn API/Web/Mobile trong repo

Thông tin tái lập đầy đủ (Reproducibility Information):

Python: 3.11.9 | OS: Windows 11 (64-bit) | Random Seed: 42 (numpy + random)

Thư viện chính đã cài (exact versions):

scikit-learn==1.9.0 | numpy==2.4.6 | pandas==3.0.5 | fastapi==0.141.1
uvicorn==0.52.4 | joblib==1.5.3 | pydantic==2.13.5 | groq==1.7.0

Bộ dữ liệu Kaggle:

- Diabetes: CDC Diabetes Health Indicators Dataset
URL: kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset
253.680 quan sát, 21 đặc trưng, nhãn Diabetes (0/1)
- House Price: Hanoi Real Estate Listings (Vietnam)
75.413 tin rao bán, 9 cột gốc → 307 chiều sau One-Hot Encoding
- Customer Behavior: Shopee Product Reviews (tiếng Việt)
9.599 bình luận, nhãn positive/negative (tỷ lệ 62/38)

Quy trình tái lập (Step-by-step):

1. Clone repo: `git clone https://github.com/Thai-DM/assignment02.git`
2. Tạo virtualenv: `python -m venv .venv && .venv\Scripts\activate`
3. Cài thư viện: `pip install -r requirements.txt`
4. Chạy notebook (optional – model đã lưu sẵn): `jupyter notebook diabetes/diabetes_notebook.ipynb`
5. Khởi động API:
 - `python diabetes/api/main.py` → `http://localhost:8001`
 - `python house_price/api/main.py` → `http://localhost:8002`
 - `python customer_behavior/api/main.py` → `http://localhost:8003`
6. Truy cập Web: `http://localhost:800x`
7. Truy cập Mobile PWA: `http://localhost:800x/mobile`

Seed cố định trong tất cả notebooks:

```
RANDOM_SEED = 42
np.random.seed(RANDOM_SEED); random.seed(RANDOM_SEED)
train_test_split(..., random_state=RANDOM_SEED, stratify=y)
```

Pipeline đã lưu (Saved Artifacts):

```
diabetes/models/diabetes_pipeline.joblib → Pipeline(StandardScaler +
DecisionTreeClassifier)
house_price/models/house_price_pipeline.joblib → Pipeline(OHE + Imputer +
Scaler + RandomForestRegressor)
customer_behavior/models/shopee_pipeline.joblib →
Pipeline(TfidfVectorizer(max_features=10000) + LinearSVC)
```

Cách nạp lại pipeline: `pipeline = joblib.load('models/xxx_pipeline.joblib')`

```
Inference: y_pred = pipeline.predict(X_new) # X_new là DataFrame với các cột  
dùng tên
```

10. KẾT LUẬN

10.1 Bài học chính

Một hệ thống thông minh không chỉ là một mô hình học máy được huấn luyện tốt, mà là sự kết hợp đầy đủ của: dữ liệu chất lượng, biểu diễn số học đúng đắn, quy trình học máy có kiểm chứng, đánh giá khách quan, và hạ tầng phần mềm để triển khai/tương tác với người dùng cuối.

10.2 Thách thức kỹ thuật quan trọng nhất

Đảm bảo tính nhất quán giữa tiền xử lý lúc huấn luyện và lúc suy luận (tránh Data Leakage) — đặc biệt quan trọng với ứng dụng House Price (One-Hot Encoding phải xử lý đúng danh mục chưa từng gặp) và Customer Behavior (phát hiện và loại bỏ đặc trưng rò rỉ rating).

10.3 Vấn đề biểu diễn dữ liệu quan trọng nhất

Lựa chọn đúng phương pháp biểu diễn cho từng loại dữ liệu: chuẩn hóa số (Diabetes), mã hóa danh mục (House), và vector hóa văn bản TF-IDF (Customer) — mỗi lựa chọn ảnh hưởng trực tiếp đến chiều đặc trưng cuối cùng và khả năng học của mô hình.

10.4 Bài học về Machine Learning

Mô hình phức tạp hơn không phải lúc nào cũng tốt hơn: Decision Tree đơn giản đạt kết quả tương đương/tốt hơn Random Forest ở bài toán Diabetes; ngược lại Random Forest vượt trội ở House Price nhờ khả năng nắm bắt tương tác phi tuyến giữa nhiều đặc trưng danh mục.

10.5 Bài học về triển khai

Việc đóng gói toàn bộ pipeline (tiền xử lý + mô hình) thành một đối tượng duy nhất bằng joblib giúp đơn giản hóa đáng kể quá trình triển khai API, giảm thiểu rủi ro sai lệch giữa môi trường huấn luyện và môi trường sản xuất.

10.6 Đề xuất cải tiến trong tương lai

- Diabetes: bổ sung chỉ số xét nghiệm định lượng (HbA1c, glucose) nếu có để tăng độ chính xác lâm sàng.
- House Price: bổ sung đặc trưng không gian (tọa độ, khoảng cách tới trung tâm) và các mô hình boosting nâng cao (XGBoost/LightGBM).
- Customer Behavior: thử nghiệm biểu diễn embedding ngữ cảnh sâu hơn (PhoBERT tiếng Việt) để so sánh với TF-IDF truyền thống.

Raw Data → Clean → Represent → Learn → Evaluate → Persist → Deploy